

CIMENTA

Bitácora del proyecto

Inteligencia inmobiliaria cuantitativa · Ciudad de México · 2026

Registro cronológico de todo lo que hacemos en el proyecto. La entrada más reciente va arriba.

Convención de cada entrada: fecha y responsable · qué se hizo · decisiones / notas · pendientes / siguiente paso.

2026-06-13 — Recon de los 10 portales + PoC scraping (M1)

Recon técnico de los 10 (clasificación Nivel A/B)

Se probó cada portal (status, anti-bot, forma de entrega de datos). Resultado:

#	Portal	Anti-bot / entrega	Nivel
1	Inmuebles24	Cloudflare challenge (403)	B
2	Propiedades.com	Cloudflare challenge	B
3	Vivanuncios	Cloudflare “Just a moment” (403)	B
4	Lamudi	accesible (Jetty), HTML	A
5	Mercado Libre	accesible; protección profunda/API	A/B
6	Pincali	accesible (Rails), JSON-LD	A
7	Trovit	401 (agregador, requiere headers)	—
8	EasyBroker	accesible; API oficial documentada	A+
9	iCasas	accesible (Apache), HTML	A
10	Casas y Terrenos	accesible; __NEXT_DATA__	A

Los 3 más grandes están tras Cloudflare → Nivel B (su propio catálogo dice no evadir sin acuerdo).

Los 7 restantes son accesibles con HTTP normal.

PoC — Casas y Terrenos (Nivel A)

- `robots.txt` permite los listados para `User-Agent: *` (solo bloquea `/api/`, `/beta/` y bots SEO). Sin anti-bot.
- Next.js: los listados vienen en `__NEXT_DATA__` → `props.pageProps.initialState.propertyData.propertyData`. URL `/{{estado}}/{{municipio}}/{{tipo}}/{{operacion}}?page=N` (240/pág, 1-indexed); total en `estimatedTotalHits`.
- Se construyó `src/ingesta/casasyterrenos.py` (config-driven desde `config.yml`): itera alcaldías CDMX + municipios ZMVM × tipos × operaciones, pagina, filtra por `lastUpdate` (3 meses), deduplica por `id`, guarda JSONL (raw) + CSV (plano). Reanudable.
- Dependencias de la etapa: `requests`, `PyYAML` (instaladas en `cimenta_env`).
- **Prueba (Benito Juárez, 14 combos, ~45 s): 855 propiedades únicas ≤3 meses**, dedup perfecto (855 CSV = 855 JSONL = 855 ids).

Caveats de calidad de datos (anotados)

- La búsqueda por alcaldía es **geo-radial / con match de texto**: un seed devuelve propiedades de zonas vecinas. Se mitiga con dedup por `id` y la unión de todas las alcaldías.

- El campo `municipality` lo captura el broker y **a veces es incorrecto** (ej. un anuncio con coords en CDMX etiquetado “Morelia”). La señal confiable de ubicación es `_geo` (lat/lng).
- `lastUpdate` es **última actualización**, no fecha de publicación pura (el listado no la expone). Se usa como proxy de “reciente”.

Pendientes / siguiente paso

- ☐ Lanzar la corrida completa CDMX + ZMVM de Casas y Terrenos (434 combos).
- ☐ Replicar el patrón a los otros portales Nivel A (Lamudi, Pincali, iCasas, EasyBroker, Casas y Terrenos).
- ☐ Decidir qué hacer con los 3 de Cloudflare (CloakBrowser vs. acuerdo vs. excluir).

2026-06-12 — Etapa 1: portales objetivo (M1 Ingesta)

Qué se hizo

- Investigación de los principales portales para comprar inmuebles en CDMX y la ZMVM, cruzando rankings de tráfico de **Similarweb** (top 5, may-2026) y **Semrush** (abr-2026, visitas/mes).
- Se excluyeron sitios con poco inventario CDMX o no-portal (craigslist, zillow, idealista, foros).
- Se creó `config.yml` con la lista portales (objetos `{nombre, sitio}`).

Top 10 portales seleccionados

#	Portal	Sitio
1	Inmuebles24	https://www.inmuebles24.com
2	Propiedades.com	https://propiedades.com
3	Vivanuncios	https://www.vivanuncios.com.mx
4	Lamudi	https://www.lamudi.com.mx
5	Mercado Libre Inmuebles	https://inmuebles.mercadolibre.com.mx
6	Pincali	https://www.pincali.com
7	Trovit Casas	https://casas.trovit.com.mx
8	EasyBroker	https://www.easybroker.com
9	iCasas	https://www.icasas.mx
10	Casas y Terrenos	https://www.casasyterrenos.com

Decisiones / notas

- Orden por tráfico nacional; todos tienen inventario en CDMX/ZMVM.
- Trovit es agregador (útil para probar deduplicación en M1); EasyBroker es backend tipo MLS con API. Alternos a futuro: Metroscubicos, Century21, RE/MAX MX.

Pendientes / siguiente paso

- ☐ Definir la estructura de M1 (Ingesta): cómo recolectar de cada portal.
- ☐ Revisar términos de uso / `robots.txt` de cada sitio antes de scrapear.

2026-06-12 — Arranque del proyecto (Etapa 0: setup)

Qué se hizo

- Estructura base del repositorio: `app/`, `data/`, `notebooks/`, `test/`, `src/`, `docs/`, más `README.md`, `requirements.txt`, `.gitignore` y esta bitácora.
- Carpetas vacías versionadas con `.gitkeep`.
- Entorno de Anaconda `cimenta_env` con **Python 3.12** (vacío, sin dependencias todavía).
- Repositorio Git con tres ramas: `master`, `dev`, `feature/dev`.
- Remoto configurado a `https://github.com/danielomar14/cimenta_repo.git` y las tres ramas subidas.

Decisiones / notas

- Flujo de trabajo: desarrollo en `feature/dev` → pruebas en `dev` → estable en `master`.
- El entorno se mantiene vacío a propósito; las dependencias se agregarán etapa por etapa.
- Datos (`data/`) excluidos del control de versiones vía `.gitignore`.
- La bitácora se lleva en LaTeX (`BITACORA.tex`) y se renderiza a PDF (`BITACORA.pdf`) con `tectonic`.

Bloqueo detectado — Catálogo de Etapas ilegible

- El archivo `docs/context/CIMENTA-Catalogo-de-Etapas.pdf` (236 págs.) está **corrupto**: todos los bytes $\geq 0x80$ de sus streams comprimidos fueron sustituidos por el carácter de reemplazo Unicode U+FFFD (`ef bf bd`) — 823,069 ocurrencias. Es resultado de un round-trip UTF-8 que destruyó la data binaria. **No es recuperable**: ni texto ni render.
- Los demás PDFs de `docs/context/` están sanos: `Plan-Maestro-v2` (97p), `Plan-Maestro` (43p), `Bitácora-del-Jurado` (120p), `Propuesta-Inicial` (12p), `Riesgos-y-Debilidades` (17p).
- **Acción requerida**: reexportar / volver a subir una copia limpia del Catálogo de Etapas para poder avanzar etapa por etapa.

Pendientes / siguiente paso

- ☐ Obtener copia limpia de `CIMENTA-Catalogo-de-Etapas.pdf`.
- ☐ Leer el catálogo y definir la Etapa 1.