

CIMENTA

Inteligencia inmobiliaria cuantitativa

CATÁLOGO DE EJECUCIÓN · v1.0

Las primeras 10 etapas, una por una

Las etapas 1 a 10 del roadmap del Plan Maestro v2, abiertas etapa por etapa: qué es, qué resuelve, cómo se hace, qué test debe pasar y qué desbloquea cada una.

Documento CIM-2026-CE **Versión** v1.0 **Fecha** Junio 2026 **Clasificación** Confidencial

01 Short-list y análisis de portales

FICHA TÉCNICA

Bloque	Fundación y marco legal
Duración estimada	1 semana
Dependencias	Ninguna (etapa de arranque)
Entregable principal	Documento de clasificación de 10 portales con: URL base, volumen estimado de anuncios activos, tecnología anti-bot detectada, extracto relevante de ToS y robots.txt, clasificación Nivel A vs B y recomendación de acción (scraping libre / negociar acuerdo / excluir).
Punto de control / gate	10 portales priorizados, al menos 3 clasificados como Nivel A con cobertura suficiente para arrancar PoC; clasificación validada por el cofundador técnico y el asesor legal.

QUÉ ES

La **short-list y análisis de portales** es el ejercicio de inteligencia competitiva con el que CIMENTA cataloga, caracteriza y clasifica los diez principales portales de anuncios inmobiliarios que operan en la CDMX y la ZMVM. El resultado no es una lista de nombres: es un documento de trabajo que determina qué fuentes son jurídica y técnicamente aprovechables desde el día uno, cuáles requieren negociación previa y cuáles deben excluirse mientras no exista un acuerdo explícito.

La clasificación sigue el esquema de **dos niveles** que atraviesa todo el diseño de CIMENTA: **Nivel A** agrupa datos abiertos (APIs públicas, feeds de sindicación, scraping de contenido no protegido por medidas tecnológicas) y portales con los que se tiene o se puede formalizar un acuerdo de data-partnership; **Nivel B** agrupa portales con protección activa —Cloudflare Turnstile, JS-rendering, CAPTCHA— o con Términos de Servicio que prohíben la extracción automatizada. La distinción no es técnica sino legal y ética: CIMENTA **no evade** medidas tecnológicas bajo ninguna circunstancia.

Esta etapa es la primera del proyecto, no tiene dependencias y se completa en una semana. Su entregable es el insumo directo que el dictamen legal (Etapa 2) necesita para pronunciarse portal por portal, y el mapa que los spiders de la Etapa 7 seguirán.

QUÉ RESUELVE

Sin este análisis, el equipo técnico iniciaría el desarrollo de scrapers sobre portales cuya juridicidad no está establecida, acumulando deuda legal desde el primer día. El **riesgo que elimina** esta etapa es el de iniciar con fuentes Nivel B sin acuerdo, lo que expondría a CIMENTA a demandas por acceso no autorizado a sistemas (art. 211 bis del Código Penal Federal) y a responsabilidad por competencia desleal, además de vulnerar el art. 108 de la Ley Federal de Derechos de Autor, que protege a los portales como bases de datos compiladas.

El segundo riesgo que resuelve es el de **sobre-optimismo de cobertura**: asumir que los portales de mayor

volumen son accesibles y construir el producto sobre esa base, para descubrir meses después que los datos reales son inaccesibles. El jurado señaló explícitamente que el dato ralo en algunas zonas es el escenario más probable al arranque. Conocer desde la Etapa 1 cuántos anuncios son alcanzables en qué colonias permite dimensionar el plan de contingencia (arrancar en 2-3 alcaldías con soporte verificado) antes de invertir en infraestructura.

DESCRIPCIÓN DETALLADA

El proceso comienza con la **identificación y priorización de los diez portales**. El criterio de selección es volumen estimado de anuncios activos en CDMX/ZMVM —obtenido por inspección manual, datos de tráfico público (SimilarWeb, Semrush en versión gratuita) y referencias de mercado—, diversidad de cobertura geográfica por alcaldía, y presencia de segmentos específicos (terrenos, obra nueva, usos mixtos). Se documenta la URL base, el dominio técnico y la razón de inclusión en el top-10.

A continuación se ejecuta el **análisis técnico de protección anti-bot**. Para cada portal se registra: presencia de Cloudflare Turnstile o equivalente, uso de JS-rendering (SPA con React/Angular donde el contenido no está en el HTML estático), CAPTCHAs interactivos, rate-limiting agresivo y fingerprinting. Esta detección se hace con herramientas pasivas —inspección de encabezados HTTP, análisis del HTML descargado con curl, revisión del archivo robots.txt— sin intentar evasión alguna. El resultado es un indicador binario de "medida tecnológica activa" que alimenta directamente la clasificación Nivel A / Nivel B.

El tercer componente es el **análisis jurídico preliminar de Términos de Servicio y robots.txt**. Para cada portal se extrae el texto literal de las cláusulas relevantes (prohibición de scraping, derechos sobre el contenido, licencia de los anunciantes sobre sus datos) y la directiva Disallow del robots.txt. Este análisis es ejecutado por el equipo fundador, no por el despacho legal; el despacho usará este insumo en la Etapa 2 para emitir el dictamen formal. El objetivo es identificar los portales con ToS permisivos o ambiguos (candidatos Nivel A) versus los que prohíben explícitamente la extracción (candidatos Nivel B).

Dimensión de análisis	Fuente de datos	Resultado esperado
Volumen de anuncios CDMX	Inspección manual + SimilarWeb gratuito	Ranking de 1 a 10 por volumen estimado
Cobertura por alcaldía	Muestra de 50 anuncios por portal	% de anuncios en alcaldías target
Tecnología anti-bot	curl / inspección de encabezados HTTP	Bandera binaria: medida activa Sí/No
Términos de Servicio	Lectura del texto legal publicado	Extracto literal de cláusulas de scraping
robots.txt	Descarga directa de /robots.txt	Directivas Disallow relevantes
Clasificación final	Combinación de los cuatro anteriores	Nivel A / Nivel B / Excluir con razón
Recomendación de acción	Criterio editorial del equipo	Scraping libre / Negociar acuerdo / Excluir

La **clasificación Nivel A / Nivel B** es la síntesis operacional de la etapa. Un portal entra en Nivel A si se cumplen las tres condiciones simultáneamente: (i) robots.txt no prohíbe el rastreo de las rutas de anuncios, (ii) no hay medida tecnológica activa contra bots, y (iii) los ToS no contienen cláusula de prohibición expresa o la cláusula es ambigua y el dictamen legal posterior la autoriza. Un portal entra en Nivel B si incumple alguna de esas tres condiciones: el camino para él es la negociación de un acuerdo de sindicación (Etapa 8), no la evasión técnica.

El entregable final es un documento estructurado de una a dos páginas por portal —diez en total— firmado por el cofundador técnico y validado de forma preliminar por el asesor legal. Incluye la recomendación de acción concreta: qué hacer con cada portal en las siguientes doce semanas. Este documento se convierte en el Anexo de Fuentes del dictamen de la Etapa 2 y en el mapa de prioridades de la Etapa 7.

TEST QUE DEBE PASAR

La etapa se da por cerrada cuando el documento de clasificación supera las siguientes verificaciones, ejecutadas

por el cofundador técnico y el asesor legal de forma independiente.

Prueba / verificación	Criterio de aprobación
Cobertura del top-10	El documento cubre exactamente 10 portales distintos con anuncios de venta en CDMX/ZMVM; ningún portal aparece duplicado ni con URL desactualizada.
Datos de volumen documentados	Para cada portal se registra una estimación de volumen con su fuente y fecha; ningún portal aparece sin estimación (se acepta "no disponible + método alternativo").
Análisis técnico de anti-bot completo	Los 10 portales tienen registrada la presencia o ausencia de Cloudflare Turnstile, JS-rendering y CAPTCHA; la detección se hizo sin intento de evasión (documentado en el método).
Extracto literal de ToS	Cada portal tiene al menos un extracto literal (no paráfrasis) de la cláusula de scraping/uso de datos, o una nota explícita de que los ToS no mencionan el tema.
robots.txt documentado	Cada portal tiene la ruta /robots.txt analizada con las directivas Disallow relevantes transcritas literalmente.
Clasificación completa y no ambigua	Los 10 portales tienen asignada una clasificación Nivel A, Nivel B o Excluir, con la razón documentada; no hay portales sin clasificar.
Umbral mínimo de Nivel A	Al menos 3 portales clasificados como Nivel A con cobertura combinada suficiente para obtener $\geq 15,000$ anuncios únicos en alcaldías target (estimación documentada).
Validación dual	El documento tiene firma o confirmación escrita del cofundador técnico Y del asesor legal; si el asesor tiene reservas sobre algún portal, están documentadas como nota pendiente para la Etapa 2.

Deslinde técnico-legal desde el día uno

CIMENTA no evade medidas tecnológicas bajo ninguna circunstancia. El art. 211 bis CPF y el riesgo de competencia desleal hacen que la evasión de Turnstile o JS-challenge sin acuerdo previo sea un riesgo penal, no solo contractual. Si un portal de alto volumen es Nivel B y no se logra un acuerdo, la cobertura de esa fuente es cero —no "reducida"— hasta que el acuerdo se firme.

QUÉ PASA CUANDO ESTA ETAPA ESTÁ LISTA

Con la short-list aprobada, la Etapa 2 puede comenzar de inmediato: el despacho de regulación inmobiliaria recibe el documento de clasificación como insumo principal para emitir el dictamen portal por portal sobre la licitud del sourcing. Sin este insumo, el dictamen sería genérico e inaplicable.

Además, el equipo técnico tiene claridad sobre qué portales puede explorar en la Etapa 7 sin esperar el dictamen completo: los portales de Nivel A sin protección activa y con ToS permisivos pueden prototipar en paralelo. Los portales de Nivel B entran en la lista de negociación de la Etapa 8.

En términos de negocio, esta etapa establece por primera vez el perímetro real del dato disponible: cuántos anuncios son alcanzables en qué colonias. Si el Nivel A resulta insuficiente para cubrir las alcaldías target con masa crítica, se activa desde este momento la estrategia de contingencia de cobertura reducida, ahorrando semanas de desarrollo que de otro modo se construirían sobre supuestos incorrectos. La siguiente etapa —el dictamen legal fundacional— toma este mapa y lo convierte en certeza jurídica operacional.

02 Dictamen legal fundacional: ToS, Ley de Servicios Inmobiliarios DF y NOM-247

FICHA TÉCNICA

Bloque	Fundación y marco legal
Duración estimada	2 semanas
Dependencias	Etapas 1
Entregable principal	Dictamen escrito firmado por despacho regulatorio sobre los cuatro puntos; borrador de MSA/T&C B2B con cláusulas de deslinde, asignación de riesgo al cliente para verificación independiente (CUZUS/SEDUVI, RPP, gravámenes, DRO), y leyendas reglamentarias obligatorias.
Punto de control / gate	Dictamen favorable recibido; si concluye sujeción a NOM-247 o Ley de Servicios, rediseño del producto antes de Fase 1. MSA borrador disponible para firmar con primeros clientes piloto.

QUÉ ES

El **dictamen legal fundacional** es el primer documento de certeza jurídica del proyecto: un análisis escrito y firmado por un despacho especializado en regulación inmobiliaria de la CDMX que se pronuncia sobre los cuatro riesgos legales que, de no resolverse antes de operar, podrían obligar a un rediseño profundo del producto o generar responsabilidad directa para los fundadores.

Los cuatro puntos del dictamen son: (i) si CIMENTA está sujeta a la **Ley de Prestación de Servicios Inmobiliarios del Distrito Federal** y, en caso afirmativo, qué ajustes son necesarios; (ii) si la información que CIMENTA republica en sus entregables configura información comercial de casa-habitación que cae bajo la **NOM-247-SE-2021/PROFECO**, y qué leyendas son obligatorias; (iii) la licitud del esquema de **sourcing por niveles** —Nivel A con uso pleno, Nivel B solo con acuerdo firmado—; y (iv) el borrador del **contrato maestro de servicios (MSA) B2B** con las cláusulas de deslinde, limitación de responsabilidad y asignación de riesgo de verificación independiente al cliente.

Esta etapa dura dos semanas y depende directamente de la Etapa 1, cuyo documento de clasificación de portales es el insumo principal del despacho para pronunciarse sobre el punto (iii).

QUÉ RESUELVE

El modo de fallo que elimina esta etapa es el de **operar sin certeza jurídica** sobre el modelo de negocio. CIMENTA publica información sobre predios en venta, entrega dossiers con análisis de valor y rentabilidad potencial, y cobra por ello. Sin el dictamen, tres riesgos permanecen abiertos y podrían materializarse después de haber invertido meses de desarrollo.

El primero es la **recalificación como intermediario inmobiliario**: si CIMENTA cobra un porcentaje del capital colocado o un success-fee vinculado al cierre, la Ley de Servicios Inmobiliarios del DF la recalifica como

gestora, con obligaciones de registro, garantías y responsabilidades que no están en el diseño del negocio. El dictamen define exactamente qué tipos de comisión y qué estructuras de cobro son seguras. El segundo es la **responsabilidad por información comercial**: la NOM-247-SE-2021/PROFECO establece requisitos de veracidad y leyendas obligatorias para la información de casa-habitación; infringirla implica sanciones PROFECON y socava el deslinde contractual. El tercero es la **nulidad de las cláusulas de limitación de responsabilidad**: el art. 2106 del Código Civil Federal establece que el tope contractual de daños no opera ante dolo o culpa grave —por eso el MSA debe documentar el proceso de QA que acredita ausencia de culpa grave.

DESCRIPCIÓN DETALLADA

El proceso se inicia con la **selección del despacho**. El criterio es doble: experiencia acreditada en regulación inmobiliaria CDMX (Ley de Servicios Inmobiliarios DF, NOM-247, PROFECON) y capacidad para redactar contratos B2B de tecnología con cláusulas de limitación de responsabilidad. No es un despacho corporativo genérico ni un estudio especializado solo en proptech: debe tener experiencia en ambos flancos. Se solicitan tres cotizaciones con alcance definido; el costo estimado de mercado para este tipo de dictamen está en el rango de 40,000-90,000 MXN según el despacho y la extensión del MSA.

El **punto (i) del dictamen** analiza si CIMENTA cae bajo la Ley de Prestación de Servicios Inmobiliarios del DF. La ley define como sujetos obligados a quienes intermedian en operaciones de compraventa o arrendamiento a cambio de una contraprestación vinculada al cierre. CIMENTA cobra retainer mensual y fee por dossier, nunca porcentaje del capital colocado; ese deslinde es el argumento central de no-sujeción. El dictamen debe ser explícito: si el despacho concluye sujeción, el modelo de cobro se rediseña antes de operar, no después.

El **punto (ii) del dictamen** analiza la NOM-247-SE-2021/PROFECO. La norma aplica a quien provee información comercial de casas-habitación al público; CIMENTA republica precios de lista de los portales y genera estimaciones propias de valor. El despacho debe determinar qué información específica cae bajo la norma y qué leyendas son obligatorias. La leyenda central de deslinde de CIMENTA —“referencial, no avalúo; NO constituye asesoría de inversión; NO verificamos situación jurídica, registral ni gravámenes”— debe ser compatible con los requerimientos de la NOM. Si no lo es, se ajusta antes de publicar cualquier contenido.

El **punto (iii) del dictamen** formaliza el esquema de **sourcing por niveles** como política jurídicamente sólida. El despacho recibe el documento de clasificación de portales (Etapa 1) y emite un pronunciamiento portal por portal: qué fuentes son de uso pleno, cuáles requieren acuerdo previo y cuáles están excluidas. Este pronunciamiento se convierte en la política de sourcing de CIMENTA, que el equipo técnico sigue sin excepciones.

- **MSA B2B — cláusula de no-garantía**: CIMENTA entrega señal analítica, no certificación. El cliente es el único responsable de verificar CUS/SEDUVI, Registro Público de la Propiedad, libertad de gravamen, dictamen DRO y factibilidad SACMEX antes de cualquier decisión.
- **MSA B2B — tope de responsabilidad**: limitado a 12 meses de fees pagados por el cliente; compatible con art. 2106 CCF solo si el proceso de QA documentado acredita ausencia de culpa grave.
- **MSA B2B — ley aplicable y arbitraje**: ley de la CDMX; resolución por arbitraje ante la Cámara de Comercio de la Ciudad de México (o la que el despacho recomiende como estándar B2B).
- **MSA B2B — asignación de riesgo de verificación**: cláusula explícita que asigna al cliente la obligación de verificación independiente de todos los hechos jurídicos, registrales y técnicos antes de comprometer capital.
- **MSA B2B — leyendas NOM-247**: integradas como parte obligatoria del entregable, no como pie de página opcional.
- **MSA B2B — prohibición de success-fee**: el contrato excluye expresamente cualquier contraprestación

vinculada al cierre de la operación; esto es el firewall principal contra la recalificación como intermediario.

El **punto (iv) del dictamen** produce el borrador del MSA. Este borrador no es un documento de plantilla genérico: incorpora las conclusiones de los tres puntos anteriores en cláusulas operacionales específicas. El equipo fundador revisa el borrador y solicita ajustes antes de la aprobación final; el objetivo es que el MSA esté listo para firmar con los primeros clientes piloto al final de la Fase 0, sin modificaciones de último minuto. Si el dictamen concluye que hay sujeción a la NOM o a la Ley de Servicios, el rediseño del producto ocurre aquí —en Etapa 2— y no después de haber construido el motor.

TEST QUE DEBE PASAR

El dictamen se da por aprobado cuando todos los puntos siguientes están verificados por el equipo fundador y el asesor legal.

Prueba / verificación	Criterio de aprobación
Dictamen recibido y firmado	El documento está firmado por un socio del despacho (no por un asociado junior), con fecha y membrete; cubre los cuatro puntos definidos en el objetivo de la etapa.
Pronunciamiento sobre Ley de Servicios Inmobiliarios DF	El dictamen concluye explícitamente no-sujeción (con las condiciones que la sostienen) O sujeción con rediseño documentado; no hay pronunciamiento ambiguo ni pendiente.
Pronunciamiento sobre NOM-247-SE-2021	El dictamen identifica qué información de CIMENTA cae bajo la norma y lista las leyendas obligatorias; las leyendas están integradas en el borrador del MSA y en la plantilla de entregables.
Política de sourcing por niveles validada	El dictamen se pronuncia sobre cada uno de los portales del documento Etapa 1: Nivel A con uso pleno, Nivel B requiere acuerdo, o Excluir; no hay portales sin pronunciamiento.
MSA borrador disponible	El borrador del MSA cubre las seis cláusulas listadas en la descripción (no-garantía, tope de responsabilidad, ley aplicable, asignación de riesgo, leyendas NOM-247, prohibición de success-fee).
Tope de responsabilidad compatible con art. 2106 CCF	El despacho confirma por escrito que el tope es válido dado el proceso de QA documentado; si no, el proceso de QA se rediseña para satisfacer el estándar.
Sin cláusula de éxito ni % de capital	El MSA revisado por el equipo fundador no contiene ninguna referencia a comisión por cierre, porcentaje de capital colocado ni success-fee; cualquier cláusula de este tipo es motivo de rechazo.
Gate de rediseño claro	Si el dictamen concluye sujeción a NOM-247 o Ley de Servicios con impacto en el modelo de negocio, existe un documento de decisión firmado por los fundadores que define el rediseño y su plazo antes de continuar a Etapa 3.

Gate de rediseño — punto de no retorno

Si el dictamen concluye sujeción a la Ley de Servicios Inmobiliarios DF con el modelo de cobro actual, la Etapa 3 no comienza hasta que el rediseño esté documentado y aprobado. Avanzar con un modelo de negocio cuya juridicidad no está resuelta invalida el tope de responsabilidad del MSA y expone a los fundadores a responsabilidad personal.

QUÉ PASA CUANDO ESTA ETAPA ESTÁ LISTA

Con el dictamen aprobado y el MSA borrador disponible, CIMENTA tiene la certeza jurídica mínima para avanzar sin exponer a los fundadores a responsabilidades que podrían haberse evitado. La Etapa 3 —cotización del seguro E&O y constitución societaria— depende de este dictamen porque el asegurador necesita entender el modelo de negocio validado legalmente para cotizar sin exclusiones críticas.

La política de sourcing validada por el dictamen le da luz verde al equipo técnico para comenzar el desarrollo de spiders (Etapa 7) sobre los portales Nivel A, y activa formalmente las negociaciones con los portales Nivel B (Etapa 8). El MSA borrador está listo para ser presentado a los primeros prospectos durante el proceso de ventas piloto, eliminando el riesgo de negociar contratos sin respaldo legal.

En términos de riesgo del proyecto, esta etapa cierra el mayor agujero de incertidumbre de la Fase 0: después de ella, los fundadores saben exactamente en qué negocio están y en cuál no. Esa claridad es también un activo de credibilidad frente a clientes y potenciales co-inversores.

03 Cotización en firme de seguro E&O y constitución societaria

FICHA TÉCNICA

Bloque	Fundación y marco legal
Duración estimada	2 semanas
Dependencias	Etapas 1 y 2
Entregable principal	Al menos una cotización en firme de seguro E&O (mercado MX o London market via fronting) con límites y exclusiones documentadas; si no es contrateable sin exclusiones críticas, decisión documentada de rediseño hacia 'solo señal/cota, nunca cifra de retorno accionable' o constitución de vehículo con patrimonio separado. Acta constitutiva firmada; tabla de cap con equity de cofundadores (incluye founder comercial con vesting 4 años, cliff 1 año).
Punto de control / gate	Cotización E&O recibida y evaluada (gate de asegurabilidad); entidad legal constituida; founder comercial cofundador incorporado con equity reservado y lista nominal de N constructoras alcanzables en 30 días verificada.

QUÉ ES

La **cotización del seguro de Errores y Omisiones (E&O)** y la **constitución societaria** son dos acciones paralelas que juntas completan el armazón institucional de CIMENTA. El seguro E&O es la red de seguridad financiera que responde cuando un cliente alega que un análisis de CIMENTA fue defectuoso y le causó un daño patrimonial. La constitución societaria es el vehículo legal que separa el patrimonio personal de los fundadores del riesgo del negocio.

El **gate de asegurabilidad** es la pieza crítica: si el mercado asegurador no puede emitir una póliza E&O con límite suficiente y sin exclusiones de "real estate" ni "investment advice", significa que el producto —tal como está diseñado— no es asegurable a un costo razonable. En ese caso, la salida no es operar sin seguro: es rediseñar el entregable hacia "solo señal/cota, nunca cifra de retorno accionable", o constituir un vehículo con patrimonio separado que aisle la exposición. Esta decisión se toma aquí, no cuando llegue el primer reclamo.

La etapa dura dos semanas y depende del dictamen de la Etapa 2, que define el modelo de negocio sobre el que se cotiza. La constitución societaria (SA de CV o SAS) incluye la tabla de capitalización inicial con los porcentajes de equity de cada cofundador y el esquema de vesting acordado.

QUÉ RESUELVE

El riesgo que elimina esta etapa es el de **operar sin blindaje patrimonial ni transferencia de riesgo a un tercero**. CIMENTA entregará análisis que influirán en decisiones de compra de terrenos por importes que pueden superar los 10 millones de pesos por operación. Sin seguro E&O y sin entidad legal constituida, los cofundadores responden con su patrimonio personal ante cualquier reclamo, incluso los infundados.

El segundo riesgo es el de **descubrir tardíamente que el producto es inasegurable**. Las pólizas E&O del mercado mexicano tienen exclusiones estándar para servicios de asesoría en inversiones inmobiliarias ("real estate", "investment advice", "property valuation"). Si CIMENTA no resuelve ese problema de diseño ahora, cuando llegue el primer cliente grande que exija prueba de seguro, no habrá tiempo de rediseñar el producto. El jurado señaló este punto explícitamente: la asegurabilidad es un test de producto, no un trámite administrativo. El tercer riesgo es el de **conflictos de equity no resueltos entre cofundadores**. El vesting de cuatro años con cliff de un año (y en particular la incorporación del cofundador comercial) debe quedar formalizado antes de firmar contratos con clientes, porque un conflicto societario posterior no resuelto paraliza la operación.

DESCRIPCIÓN DETALLADA

El proceso del **seguro E&O** comienza con la elaboración de un brief de producto para el mercado asegurador: descripción del servicio, tipos de clientes, volúmenes de transacción que influencia el producto, cobertura geográfica y el dictamen legal de la Etapa 2 como evidencia de cumplimiento regulatorio. Este brief se envía a tres o cuatro brokers especializados en seguros de responsabilidad profesional para empresas de datos y tecnología en México; si el mercado local no tiene capacidad suficiente, se explora el **London Market vía fronting** (asegurador local que cede el riesgo a reaseguradores de Lloyd's o similares).

El criterio de evaluación de la cotización es específico y no negociable: límite de indemnización igual o superior al daño-proyecto en el percentil 95 (estimado a partir del valor promedio de los proyectos que los clientes ICP-1 e ICP-2 ejecutarán), sin exclusión de "real estate" como clase de activo subyacente y sin exclusión de "investment advice" si el entregable de CIMENTA es caracterizable como tal por el asegurador. Si las tres cotizaciones incluyen esas exclusiones, hay dos salidas posibles: (i) **rediseño del entregable** hacia "señal/cota sin cifra de retorno accionable" —esto es, presentar rangos probabilísticos sin recomendar explícitamente una acción de compra—; o (ii) **vehículo con patrimonio separado** que limite la exposición al capital de la entidad operativa.

- **Límite mínimo de la póliza E&O:** igual o superior al valor del proyecto p95 del ICP-1 (estimado en 2-5 MDP por operación individual) multiplicado por el número de proyectos simultáneos que el cliente podría ejecutar con base en el análisis de CIMENTA.
- **Exclusiones que hacen inviable la póliza sin rediseño:** "real estate" como clase de activo subyacente, "investment advice" o "property valuation" si el entregable no se puede distinguir de esas categorías.
- **Exclusiones aceptables:** ciberriesgo (cubierto por póliza separada), daños físicos a la propiedad, actos fraudulentos del asegurado.
- **Costo estimado de mercado:** entre 0.5% y 1.5% del límite asegurado anual en el mercado mexicano; el London Market puede ser más competitivo para límites altos.
- **Documentación requerida por el asegurador:** dictamen legal (Etapa 2), borrador del MSA, descripción del proceso de QA, perfil de clientes y volúmenes de transacción referenciados.

La **constitución societaria** corre en paralelo. La decisión entre SA de CV y SAS depende de tres factores: número de socios, capacidad de emitir acciones preferentes para rondas futuras y costo de mantenimiento contable. La **SAS** (Sociedad por Acciones Simplificada) es más ágil para equipos pequeños y se constituye en línea, pero tiene límites de capital y restricciones para ciertas estructuras de inversión. La **SA de CV** es más costosa y requiere notario, pero es el vehículo estándar para rondas de capital y emisión de acciones preferentes. El despacho legal de la Etapa 2 recomienda la estructura apropiada dado el plan de capitalización.

La **tabla de capitalización (cap table) inicial** incluye: equity del cofundador técnico, equity del cofundador comercial (con vesting de cuatro años y cliff de un año desde la fecha de incorporación formal), reserva para

opciones de empleados futuros (ESOP pool, típicamente 10-15% pre-ronda), y cualquier equity prometido a asesores estratégicos. El vesting del cofundador comercial se formaliza en un acuerdo de co-fundación firmado con la misma fecha que el acta constitutiva. La **lista nominal de N constructoras alcanzables en 30 días** —que el cofundador comercial entrega como parte de su incorporación— se verifica como activo real, no como promesa: al menos una reunión agendada o un contacto con respuesta positiva por cada constructora de la lista.

TEST QUE DEBE PASAR

La etapa cierra cuando el gate de asegurabilidad está evaluado, la entidad legal existe y el equity está formalizado.

Prueba / verificación	Criterio de aprobación
Cotizaciones E&O recibidas	Se recibieron al menos dos cotizaciones de brokers distintos (mercado MX o London Market vía fronting) con límites, exclusiones y prima documentadas por escrito.
Gate de asegurabilidad evaluado	Existe un documento de decisión firmado por los fundadores que concluye: (a) póliza contratada con límite y exclusiones aceptables, O (b) póliza no contratada sin exclusiones críticas + decisión documentada de rediseño de producto o vehículo de patrimonio separado.
Límite suficiente verificado	Si la póliza se contrató, el límite es $\geq$ daño-proyecto p95 estimado (cálculo documentado con supuestos explícitos sobre valor de proyecto y número de posiciones simultáneas del cliente).
Entidad legal constituida	Existe acta constitutiva firmada ante notario (SA de CV) o registro SIREN (SAS) con número de registro y RFC; la entidad no tiene nombre diferente al aprobado por los fundadores.
Cap table firmado	La tabla de capitalización inicial está firmada por todos los cofundadores; incluye porcentajes de equity, clase de acción, esquema de vesting (4 años, cliff 1 año) y ESOP pool reservado.
Vesting del cofundador comercial formalizado	El acuerdo de co-fundación del cofundador comercial está firmado con fecha y cláusula de cliff explícita; el equity no está sujeto a condiciones no documentadas.
Lista nominal de constructoras verificada	La lista de N constructoras alcanzables en 30 días entregada por el cofundador comercial tiene al menos una evidencia de contacto activo (respuesta a correo, reunión agendada) por cada empresa listada.
Infraestructura cloud básica levantada	Como parte de la operación inicial, el entorno de nube (instancia PostgreSQL+PostGIS, almacenamiento, repositorio de código) está provisionado y accesible; esto es requisito de la Etapa 6.

El gate de asegurabilidad es un test de diseño de producto

Si ningún asegurador puede emitir E&O sin excluir "real estate" o "investment advice", el mercado está diciendo que el entregable de CIMENTA es percibido como asesoría de inversión inmobiliaria. En ese caso, el rediseño del entregable —hacia rangos probabilísticos sin recomendación de compra— no es un retroceso: es la definición correcta del producto desde el inicio. Operar sin seguro adecuado y sin ese rediseño invalida el tope de responsabilidad del MSA.

QUÉ PASA CUANDO ESTA ETAPA ESTÁ LISTA

Con la entidad legal constituida, el seguro E&O evaluado y el equity formalizado, CIMENTA existe como empresa

operativa y sus fundadores tienen sus roles y derechos documentados. Esto desbloquea dos ramas del plan en paralelo.

La primera rama es la **Etapas 4 (marco de privacidad y EIPD)**, que requiere que la entidad legal exista para nombrar un responsable de datos y registrar la EIPD ante la Secretaría Anticorrupción y Buen Gobierno. Sin RFC y sin entidad legal, ese registro no es posible.

La segunda rama es la **Etapas 6 (PoC de ingesta Nivel A)**, que en el plan depende de que la infraestructura cloud esté levantada —lo que ocurre como parte de la operación inicial de la empresa constituida. El cofundador técnico puede iniciar la carga de datos abiertos de INEGI, SEDUVI y OSM en cuanto la instancia de PostgreSQL+PostGIS esté operativa.

En términos de credibilidad ante el mercado, la combinación de entidad legal + dictamen legal + seguro E&O evaluado es el paquete mínimo que un cliente ICP-1 (constructora mediana) o ICP-2 (family office) necesita ver antes de firmar un MSA y pagar el retainer. Sin estos tres elementos, el proceso de ventas piloto no puede avanzar más allá de la conversación exploratoria.

04 Marco de privacidad y EIPD bajo nueva LFPDPPP 2025

FICHA TÉCNICA

Bloque	Fundación y marco legal
Duración estimada	2 semanas
Dependencias	Etapa 3
Entregable principal	Aviso de privacidad publicable (anunciantes + clientes B2B); EIPD registrada ante la Secretaría Anticorrupción y Buen Gobierno (SABG, autoridad desde DOF marzo 2025); cláusulas de encargo para proveedor de LLM y cloud (NO-reentrenamiento, transferencia internacional con garantías); política interna de mínimos de datos (sin teléfonos/nombres, fotos difuminadas, motivación del vendedor solo agregada por colonia).
Punto de control / gate	EIPD registrada; aviso publicado y operable; cláusulas de encargo firmadas con proveedor LLM y cloud. El reloj regulatorio de DATOS/CONSUMIDOR tiene su primera entrada versionada (LFPDPPP 2025, Reglamento pendiente marcado como alerta).

QUÉ ES

El **marco de privacidad y la Evaluación de Impacto a la Protección de Datos (EIPD)** son la respuesta de CIMENTA al régimen regulatorio más reciente y más exigente de su operación: la **Ley Federal de Protección de Datos Personales en Posesión de Particulares reformada** (LFPDPPP, publicada en el DOF en marzo de 2025), cuya autoridad de aplicación es ahora la **Secretaría Anticorrupción y Buen Gobierno (SABG)**, no el INAI —que dejó de ser la autoridad en datos personales del sector privado bajo el nuevo texto.

CIMENTA trata datos personales de dos tipos de titulares con situaciones jurídicas muy distintas. El primer tipo es el **anunciante-vendedor**: la persona física o moral que publicó su propiedad en un portal inmobiliario. CIMENTA extrae esos datos sin relación contractual con el anunciante; la base de licitud es frágil ("fuente de acceso público") y se debilita cuando los Términos de Servicio del portal son restrictivos —en ese escenario, la base correcta es "fuente con licencia" derivada del acuerdo de sindicación. El segundo tipo es el **cliente B2B**: la constructora o el despacho patrimonial que firma el MSA; aquí la base de licitud es contractual y es robusta.

El tratamiento más riesgoso no es la recolección del precio del anuncio: es la **inferencia de motivación o urgencia del vendedor** a partir del texto del anuncio mediante LLM. Esa inferencia es una decisión automatizada con efecto económico potencial sobre el titular, lo que activa el derecho de oposición y el requisito de human-in-the-loop bajo la nueva ley.

QUÉ RESUELVE

El riesgo principal que elimina esta etapa es el de **iniciar el perfilamiento de anunciantes sin base de licitud sólida ni canal ARCO operable**. La LFPDPPP 2025 establece que el tratamiento de datos para perfilamiento con efectos económicos es tratamiento de alto riesgo, y la EIPD es obligatoria antes de iniciar ese tratamiento

—no después de que la SABG lo detecte. Iniciar sin EIPD es una infracción administrativa cuya sanción puede llegar a porcentajes de los ingresos anuales de la empresa.

El segundo riesgo es el de **transferencia internacional de datos sin garantías**. CIMENTA usará proveedores de LLM y nube que procesan datos en servidores fuera de México (típicamente en Estados Unidos o Europa). La LFPDPPP 2025 exige que la transferencia internacional esté amparada por cláusulas contractuales de encargo que prohíban el re-entrenamiento de modelos con los datos de los titulares y que establezcan garantías equivalentes a las del marco mexicano. Sin esas cláusulas firmadas, el proveedor de LLM no es un encargado sino un responsable independiente —lo que cambia radicalmente la exposición regulatoria.

El tercer riesgo es de diseño de producto: si la política interna no prohíbe el almacenamiento de datos individuales sensibles (teléfonos, nombres completos, fotos no difuminadas), el acervo de datos de CIMENTA se convierte en un pasivo de privacidad que crece semana a semana sin que los fundadores lo perciban hasta que llegue la primera solicitud ARCO o la primera auditoría.

DESCRIPCIÓN DETALLADA

El trabajo comienza con el **mapeo de flujos de datos** (data flow mapping). Para cada tipo de dato que CIMENTA procesa —precio, dirección, descripción del inmueble, fotos, nombre del anunciante, teléfono de contacto, texto libre del anuncio— se documenta: fuente de origen (portal + clasificación Nivel A/B), base de licitud aplicable, operación de tratamiento (recolección, almacenamiento, análisis, transferencia), destinatarios (proveedor LLM, proveedor cloud, cliente B2B), plazo de retención y mecanismo de borrado. Este mapeo es el insumo de la EIPD.

La **política de mínimos de datos** es la primera decisión de diseño de este mapeo: CIMENTA almacena lo mínimo necesario para cumplir su función analítica. Concretamente: (i) **no se almacenan teléfonos ni nombres de contacto** de los anunciantes —estos son datos de contacto personal sin valor analítico para el AVM—; (ii) **las fotos se procesan para extracción de features y se descartan** o se almacenan difuminadas; (iii) la **motivación o urgencia inferida del vendedor** (p. ej., "urge vender", "por mudanza") se agrega a nivel colonia-mes como señal estadística y **no se almacena como atributo individual** del anuncio —esto es el mecanismo de human-in-the-loop y de k-anonimato aplicado al perfilamiento individual.

El **aviso de privacidad para anunciantes-no-clientes** es el documento de cara al titular. Su particularidad es que el titular no tiene relación contractual con CIMENTA y probablemente nunca lo sabrá directamente. El aviso se publica en el sitio web de CIMENTA de forma accesible, menciona explícitamente la fuente de los datos (el portal del que se extrajeron), la base de licitud (fuente de acceso público con licencia del portal + minimización), las finalidades del tratamiento y, de forma destacada, el **canal ARCO operable sin relación previa**: un correo electrónico designado o un formulario web donde cualquier persona puede solicitar acceso, rectificación, cancelación u oposición sin necesidad de haber sido cliente o de probar su identidad de forma onerosa.

- **Derecho de OPOSICIÓN específico a elaboración de perfiles**: el aviso de privacidad menciona explícitamente que CIMENTA elabora perfiles de inmuebles que pueden incluir inferencias sobre características del proceso de venta; el titular puede oponerse a ese tratamiento específico, y CIMENTA debe proceder al borrado de las inferencias LLM asociadas al anuncio del titular dentro del plazo legal.
- **EIPD registrada ante la SABG**: la Evaluación de Impacto a la Protección de Datos identifica el perfilamiento de anunciantes como tratamiento de alto riesgo, documenta las medidas de mitigación adoptadas (k-anonimato, política de mínimos, canal ARCO, cláusulas de encargo) y se registra ante la SABG como exige la LFPDPPP 2025.
- **Cláusulas de encargo con proveedor LLM**: el contrato con el proveedor de modelo de lenguaje incluye:

prohibición de re-entrenamiento de modelos con datos de titulares mexicanos, garantías de transferencia internacional equivalentes al marco mexicano, obligación de borrado a petición de CIMENTA, y auditoría de cumplimiento anual.

- **Cláusulas de encargo con proveedor cloud:** mismas garantías de transferencia internacional, más cifrado en tránsito y en reposo, segregación lógica de datos de diferentes clientes y tiempo máximo de respuesta ante brechas de seguridad.
- **Nombramiento de responsable de datos:** una persona física dentro de la organización (o el despacho externo) designada formalmente como responsable de atender solicitudes ARCO y de mantener actualizado el registro de tratamientos.
- **Reloj regulatorio — primera entrada de datos/consumidor:** la LFPDPPP 2025 tiene Reglamento pendiente de publicación; el reloj regulatorio de CIMENTA registra esta fecha como alerta activa y asigna responsable de seguimiento.

El **aviso de privacidad para clientes B2B** es distinto al de anunciantes: aquí la base de licitud es contractual (el MSA firmado), las finalidades son las del servicio contratado, y el tratamiento de datos del cliente (nombre del representante legal, RFC, datos de contacto) es estándar. Sin embargo, el aviso debe mencionar que CIMENTA no comparte datos del cliente con otros clientes bajo ninguna circunstancia —esto es también el fundamento del firewall de outcomes de COFECE (Etapa 5).

La EIPD se presenta ante la SABG con los formularios que la autoridad publique bajo el nuevo marco; si el Reglamento de la LFPDPPP 2025 aún no está publicado al momento de esta etapa, se sigue el proceso de registro más reciente disponible y se deja constancia de que la EIPD será actualizada cuando el Reglamento entre en vigor. Esta documentación proactiva es evidencia de buena fe ante cualquier revisión posterior de la SABG.

TEST QUE DEBE PASAR

La etapa cierra cuando los documentos están publicados, registrados y las cláusulas de encargo están firmadas.

Prueba / verificación	Criterio de aprobación
Aviso de privacidad publicado — anunciantes	El aviso de anunciantes-no-clientes está publicado en el sitio web de CIMENTA en una URL permanente; menciona base de licitud, finalidades, canal ARCO, derecho de oposición a perfilamiento y fuente de los datos.
Aviso de privacidad publicado — clientes B2B	El aviso de clientes B2B está integrado en el MSA o publicado como documento vinculado; menciona finalidades, transferencias a proveedores (LLM, cloud) y ausencia de compartición con terceros clientes.
Canal ARCO operable sin relación previa	Existe un correo o formulario web activo designado para solicitudes ARCO; se probó con una solicitud de prueba y el tiempo de respuesta estimado está documentado (máximo 20 días hábiles conforme a la ley).
EIPD registrada ante la SABG	Existe acuse de recibo o número de folio del registro de la EIPD ante la SABG; si el Reglamento no está publicado, existe constancia de presentación con nota de actualización pendiente.
Política de mínimos de datos implementada	El pipeline de datos (configuración verificada en código) no almacena teléfonos ni nombres de anunciantes; las fotos tienen proceso de descarte o difuminado; la motivación del vendedor no se almacena como atributo individual.
Cláusulas de encargo firmadas — LLM	El contrato con el proveedor de LLM incluye cláusulas de no-reentrenamiento, transferencia internacional con garantías, borrado a petición y auditoría anual; el contrato está firmado (no solo enviado).
Cláusulas de encargo firmadas — cloud	El contrato con el proveedor cloud incluye cifrado en tránsito y en reposo, segregación lógica, tiempo máximo de respuesta ante brechas; el contrato está firmado.
Reloj regulatorio — primera entrada datos/consumidor	El reloj regulatorio tiene una entrada versionada que registra: LFPDPPP 2025 (DOF marzo 2025), Reglamento pendiente como alerta activa, responsable de seguimiento designado y fecha estimada de publicación del Reglamento.

La motivación del vendedor no se almacena como atributo individual

La inferencia LLM de "urgencia" o "motivación del vendedor" es la señal analítica más valiosa y la más riesgosa desde el punto de vista de privacidad: es una decisión automatizada con efecto económico potencial sobre el titular. La regla operacional es terminante: esa señal se agrega a nivel colonia-mes y se descarta a nivel de anuncio individual. Cualquier excepción requiere aprobación del responsable de datos y actualización de la EIPD.

QUÉ PASA CUANDO ESTA ETAPA ESTÁ LISTA

Con el marco de privacidad en vigor y la EIPD registrada, CIMENTA puede iniciar el tratamiento de datos de anunciantes con base de licitud documentada. Esto desbloquea directamente la **Etapa 5 (memos COFECE)**, que analiza los riesgos de competencia económica de la mecánica de exclusividad del entregable y del flujo de información entre suscriptores —análisis que requiere saber exactamente qué datos se tratan y bajo qué condiciones.

El aviso de privacidad publicado y el canal ARCO operativo son también condición para que el frontend de la Etapa 33 pueda presentar datos a clientes sin violar la ley: un sistema que muestra datos de anunciantes sin aviso publicado y sin canal ARCO activo es una infracción en operación continua.

Desde el punto de vista del reloj regulatorio, esta etapa instala la infraestructura de seguimiento que permitirá a CIMENTA adaptarse al Reglamento de la LFPDPPP 2025 cuando se publique, sin que esa publicación genere una crisis de cumplimiento. La documentación proactiva —la EIPD registrada antes de iniciar el perfilamiento masivo— es el activo de buena fe más valioso frente a la SABG en cualquier revisión futura.

05 Memos COFECE: exclusividad de entregable e inputs, y hub-and-spoke de outcomes

FICHA TÉCNICA

Bloque	Fundación y marco legal
Duración estimada	2 semanas
Dependencias	Etapas 4
Entregable principal	Dos memos COFECE escritos con conclusión y condiciones de cumplimiento; política interna de firewall de outcomes (de-identificación, k-anonimato $K \geq 5$ espacial, prohibición de revelar datos de compra de un suscriptor a otro en colonias con $<K$ competidores activos, agregación colonia-mes histórica, firewall auditable documentado).
Punto de control / gate	Dos memos recibidos con conclusión operacional clara; política de firewall implementada en el diseño del sistema antes de activar telemetría. Si algún memo concluye riesgo material, se ajusta la mecánica antes de Fase 1.

QUÉ ES

Los **memos COFECE** son dos análisis escritos de derecho de competencia económica encargados al despacho especializado en regulación económica, distintos del despacho de regulación inmobiliaria de la Etapa 2. Su propósito es verificar que dos mecánicas específicas del modelo de negocio de CIMENTA no configuran prácticas monopolísticas relativas bajo los artículos 9-11 de la **Ley Federal de Competencia Económica (LFCE)**: el intercambio de información sensible entre competidores (hub-and-spoke) y el reparto de mercado por exclusividad temporal.

El primer memo analiza la **exclusividad temporal sobre el entregable analítico**: cuando CIMENTA entrega a un cliente un dossier sobre un predio específico, ¿puede reservar ese entregable por N días antes de ofrecerlo a otro suscriptor competidor del mismo predio? La respuesta importa porque si la exclusividad se estructura incorrectamente, CIMENTA podría ser calificada como un hub que facilita el reparto de información comercial sensible entre constructoras que compiten por los mismos terrenos.

El segundo memo analiza el **hub-and-spoke de outcomes**: si CIMENTA recolecta telemetría de resultados de sus suscriptores (qué predios compraron, a qué precio, qué márgenes obtuvieron) y usa esa información para mejorar sus modelos, ¿eso configura un flujo de información ex-post que coordina horizontalmente a los suscriptores? Este memo debe responderse antes de activar cualquier sistema de retroalimentación de resultados.

QUÉ RESUELVE

El riesgo que elimina esta etapa es el de **construir una mecánica de producto que, sin intención de serlo, funciona como coordinador de información entre competidores**. La COFECE ha sancionado esquemas hub-

and-spoke en México en sectores distintos al inmobiliario; la precedencia existe y el riesgo no es teórico. Una sanción de competencia económica puede llegar a porcentajes del ingreso anual y genera responsabilidad penal individual para los directivos.

El segundo riesgo que resuelve es el de **diseñar la exclusividad del dossier como activo de valor sin saber si es legalmente sostenible**. CIMENTA planea que parte de su propuesta de valor para los suscriptores sea la ventana de tiempo en que solo ellos tienen acceso al análisis de un predio específico. Si ese esquema no supera el análisis COFECE, la alternativa —“prioridad temporal de atención” sin reserva formal— debe diseñarse desde el inicio, no modificarse después de que los primeros contratos estén firmados con promesas de exclusividad que no se pueden cumplir legalmente.

El tercer elemento que esta etapa instala es la **política interna de firewall de outcomes**: un conjunto de reglas operacionales de de-identificación, k-anonimato espacial y prohibición de compartición que hacen que el flujo de información de telemetría de suscriptores sea analíticamente útil para CIMENTA sin configurar coordinación horizontal.

DESCRIPCIÓN DETALLADA

El **primer memo — exclusividad del entregable** comienza con una descripción precisa de la mecánica para el despacho de competencia: CIMENTA identifica un predio como oportunidad, genera un dossier analítico, y lo ofrece primero a un suscriptor por un período N (por ejemplo, 72 horas o 7 días). Transcurrido ese período, el mismo dossier puede ofrecerse a otro suscriptor competidor en la misma colonia. La pregunta al despacho es si esta mecánica, en el contexto del mercado de terrenos en CDMX donde los compradores son un número limitado de constructoras que se conocen y compiten directamente, configura reparto de información comercial sensible bajo los artículos 9 y 11 de la LFCE.

El memo debe analizar específicamente tres variantes de la mecánica y pronunciarse sobre cada una: (i) **exclusividad sobre el entregable analítico** (el dossier con el análisis de CIMENTA, no sobre el predio físico): es CIMENTA quien reserva su propio análisis, no quien reserva el derecho del comprador al predio; (ii) **ventana corta sin condición de adquisición**: el acceso prioritario no está condicionado a que el suscriptor se comprometa a comprar, lo que evita que funcione como mecanismo de reserva de mercado; (iii) **degradación a “prioridad temporal de atención” sin reserva formal**: si las variantes (i) y (ii) presentan riesgo, esta alternativa —que CIMENTA atiende primero la solicitud del suscriptor prioritario pero no hace ninguna promesa de exclusividad— es la salida operacional.

El **segundo memo — hub-and-spoke de outcomes** describe el flujo de telemetría que CIMENTA planea activar en fases posteriores: cuando un suscriptor usa un dossier de CIMENTA y eventualmente adquiere (o no) el predio analizado, esa información de resultado retroalimenta el modelo para mejorar las estimaciones futuras. El despacho debe analizar si ese flujo —donde CIMENTA actúa como hub entre suscriptores competidores que aportan información de resultados como spokes— configura coordinación horizontal aunque cada suscriptor no sepa qué hacen los demás.

- **K-anonimato espacial $K \geq 5$** : ningún dato de outcome de un suscriptor individual se incorpora a los modelos si en la colonia o AGEB correspondiente hay menos de 5 compradores activos distintos; en celdas con menos de K competidores, la telemetría de ese suscriptor específico se descarta.
- **Agregación colonia-mes histórica**: los outcomes se agregan a nivel de colonia y período mensual antes de usarse como señal de entrenamiento; ningún dato individual de compra, precio pagado ni margen de un suscriptor específico es visible para el equipo de CIMENTA que atiende a otros suscriptores.
- **Firewall de acceso interno**: el equipo comercial de CIMENTA no tiene acceso a los outcomes individuales

de ningún suscriptor; solo el equipo de ciencia de datos accede a los datos agregados para reentrenamiento, con un protocolo de acceso documentado.

- **Prohibición de compartición cross-suscriptor:** ningún dato de comportamiento o resultado de un suscriptor A se comparte con el suscriptor B bajo ninguna forma, incluyendo señales indirectas como "este predio ya tiene interés de otro cliente".
- **Auditoría documentada del firewall:** el diseño del sistema incluye desde el inicio un log de accesos a datos de outcomes, revisable en caso de investigación de COFECE; el log es parte del sistema de QA de la Etapa 35.
- **Etiqueta de dossier sin mención de competidores:** ningún dossier menciona si otro suscriptor ha visto el mismo análisis, recibido una propuesta similar o expresado interés en el mismo predio o colonia.

La **política interna de firewall de outcomes** no es solo un documento: es un conjunto de restricciones técnicas implementadas en el diseño del sistema antes de activar cualquier telemetría. El despacho de competencia revisará el diseño del firewall y emitirá su opinión sobre si es suficiente para mitigar el riesgo hub-and-spoke. Si el memo concluye riesgo material con el diseño propuesto, la telemetría de outcomes no se activa hasta que el rediseño esté aprobado.

La **ventana de exclusividad del entregable** —si el primer memo la aprueba— se fija como parte del MSA y de la propuesta de valor de los niveles de suscripción: un suscriptor de nivel básico no tiene ventana de exclusividad; un suscriptor de retainer mensual tiene una ventana de N días sobre los dossiers que solicita activamente. Esa diferenciación por nivel de servicio es el mecanismo de monetización de la exclusividad sin que CIMENTA garantice que nadie más verá el predio —garantía que sería imposible de cumplir y que configuraría el riesgo más claro de intermediación.

TEST QUE DEBE PASAR

La etapa cierra cuando ambos memos están recibidos con conclusión operacional clara y la política de firewall está implementada en el diseño del sistema.

Prueba / verificación	Criterio de aprobación
Memo de exclusividad del entregable recibido	El primer memo está firmado por el despacho de competencia y tiene una conclusión operacional explícita sobre al menos dos de las tres variantes analizadas (exclusividad sobre el entregable, ventana corta sin condición, o prioridad temporal sin reserva).
Conclusión operacional del memo de exclusividad	La conclusión del memo es accionable: o aprueba una variante específica con las condiciones que debe cumplir, o concluye riesgo material y señala la alternativa sin riesgo; no hay pronunciamiento ambiguo pendiente de aclaración.
Memo hub-and-spoke de outcomes recibido	El segundo memo está firmado por el despacho de competencia y se pronuncia sobre el flujo de telemetría de outcomes descrito; incluye evaluación específica del k-anonimato $K \geq 5$ como mitigante.
Conclusión operacional del memo hub-and-spoke	La conclusión del memo aprueba el flujo de telemetría con el firewall diseñado, o concluye riesgo material y define las modificaciones necesarias antes de activar telemetría.
Política de firewall de outcomes documentada	Existe un documento interno de política de firewall que incluye: k-anonimato $K \geq 5$, agregación colonia-mes, firewall de acceso interno, prohibición de compartición cross-suscriptor, protocolo de log auditable; la política está firmada por los fundadores.
Firewall implementado en el diseño del sistema	El diseño de arquitectura del pipeline de datos (documentado en código o diagrama) refleja las restricciones del firewall antes de activar cualquier telemetría de outcomes; no hay rutas de datos que violen la política.
Gate de ajuste pre-Fase 1	Si algún memo concluye riesgo material, existe un documento de decisión firmado que define el ajuste a la mecánica y confirma que no se activa la funcionalidad afectada hasta que el ajuste esté implementado y revisado.
Mecánica de exclusividad integrada en el MSA	Si el primer memo aprueba alguna variante de exclusividad, el MSA (borrador de Etapa 2) está actualizado con la cláusula correspondiente; si no la aprueba, el MSA no menciona exclusividad sino "prioridad de atención".

La exclusividad es sobre el entregable analítico, nunca sobre el predio

CIMENTA nunca vende ni reserva el derecho de compra sobre un predio. La exclusividad —si los memos la aprueban— es sobre el dossier analítico propio de CIMENTA: el suscriptor tiene acceso prioritario al análisis durante una ventana de tiempo. Cualquier lenguaje comercial que sugiera que CIMENTA "reserva" el predio para el cliente es incorrecto, configura riesgo de intermediación bajo la Ley de Servicios Inmobiliarios DF y viola el deslinde del MSA.

QUÉ PASA CUANDO ESTA ETAPA ESTÁ LISTA

Con los dos memos recibidos y la política de firewall implementada en el diseño, CIMENTA completa el bloque de **Fundación y Marco Legal** (Etapas 1-5). Este bloque es el prerequisite de todo el desarrollo técnico posterior: los modelos, el motor y el frontend se construyen sobre un armazón jurídico definido, no sobre supuestos que podrían invalidarse meses después.

En términos de arquitectura de producto, el firewall de outcomes queda integrado desde el inicio en el diseño del pipeline de datos —no como un parche posterior. La mecánica de exclusividad del entregable queda definida como parte del MSA, lo que permite al equipo comercial hacer promesas precisas a los prospectos durante el proceso de ventas piloto.

La siguiente etapa (**Etapas 6 — PoC de ingesta Nivel A**) ya puede ejecutarse en paralelo con las Etapas 4 y 5, dado que sus dependencias son la Etapa 3 (infraestructura cloud levantada) y no el resultado de los memos. Sin

embargo, los resultados de los memos son necesarios antes de activar cualquier funcionalidad de telemetría o exclusividad en el producto, que corresponde a etapas mucho más avanzadas del plan. El bloque de Fundación cierra con CIMENTA sabiendo exactamente qué puede hacer, cómo puede cobrarlo y con qué estructura de riesgo operará.

06 PoC de ingesta Nivel A: INEGI, DENUE, SEDUVI y OSM

FICHA TÉCNICA

Bloque	Ingesta y datos
Duración estimada	2 semanas
Dependencias	Etapas 3 (infraestructura cloud levantada como parte de la constitución operacional)
Entregable principal	Base PostGIS con capas INEGI/DENUE/SEDUVI/OSM cargadas, indexadas y validadas por alcaldía; script de actualización automatizable; reporte de cobertura con % de predios con CUS asignado por alcaldía; primera versión del reloj regulatorio urbano con fecha de vigencia de cada capa.
Punto de control / gate	>=80% de predios en alcaldías target con CUS asignado desde padrón CUZUS/SEDUVI; grafo peatonal OSM cargado y enrutable con PostGIS/pgRouting o OSRM local; reloj regulatorio con primera entrada versionada.

QUÉ ES

La Etapa 6 construye el esqueleto geoespacial del producto: las capas de datos abiertos que ningún portal puede sustituir. Se ingestan y cargan en PostgreSQL+PostGIS las manzanas y AGEBS del Marco Geoestadístico INEGI, el DENUE del último trimestre disponible, los predios y uso de suelo de manzana de los datos abiertos CDMX, el padrón de **Certificados Únicos de Zonificación de Uso de Suelo (CUZUS)** y las Constancias y Dictámenes de Cambio de Uso emitidos por SEDUVI, la zonificación ZEDEC vigente, y la red peatonal OSM bajo licencia ODbL. El resultado es una base PostGIS indexada, particionada por alcaldía y con scripts de actualización automatizables. Se genera también la primera entrada del **reloj regulatorio urbano**: un registro versionado con la fecha de vigencia de cada capa, que permite reproducir el estado normativo en cualquier fecha pasada.

QUÉ RESUELVE

El jurado identificó como riesgo crítico arrancar modelos sobre un esqueleto geoespacial incompleto o con uso de suelo desactualizado: cualquier cifra de potencial constructivo calculada sobre el uso de manzana del PGOT sin cruzar con constancias individuales SEDUVI produce falsos positivos que destruyen credibilidad ante el ICP-1 (constructoras). Esta etapa resuelve ese riesgo antes de tocar un solo anuncio de portal. Un segundo riesgo cubierto es la **replicabilidad point-in-time**: si el regulatorio cambia entre la fecha del dossier y la visita del cliente al predio, CIMENTA debe poder demostrar que el CUS emitido en el entregable era el vigente en esa fecha. El reloj regulatorio es la evidencia. Sin las capas INEGI cargadas tampoco es posible hacer snap de coordenadas a predio/manzana en E9, ni enrutar isócronas peatonales en E19.

DESCRIPCIÓN DETALLADA

La ingesta parte de tres fuentes con formatos heterogéneos que requieren transformaciones distintas. El Marco Geoestadístico INEGI se distribuye en Shapefile por entidad federativa; se recorta a las 16 alcaldías CDMX, se reproyecta a EPSG:4326, se carga en tablas separadas (manzanas, AGEBS, localidades) y se indexa con GIST. El DENUÉ se distribuye en CSV con coordenadas WGS84; se importa con COPY y se geocruza contra las manzanas INEGI para asignar clave_manzana como llave de unión. Los datos abiertos CDMX (portal datos.cdmx.gob.mx) incluyen la capa de predios con clave catastral y uso de suelo de manzana en GeoJSON: se valida la cobertura por alcaldía y se registra el porcentaje de predios con geometría válida (meta: menos de 2% de geometrías inválidas tras ST_MakeValid).

- **Marco Geoestadístico INEGI:** manzanas y AGEBS 2023 en PostGIS, reproyectadas a EPSG:4326, índice GIST sobre geometría; clave_manzana como llave de unión cross-table.
- **DENUÉ (último trimestre):** importación CSV, geocruce a manzana INEGI, índice espacial y de texto sobre nombre_act para consultas de cambio de giro comercial (señal adelantada E20).
- **Datos abiertos CDMX - predios:** GeoJSON con clave catastral y uso de suelo de manzana; validación de cobertura por alcaldía; menos de 2% geometrías inválidas tras ST_MakeValid.
- **Padrón CUZUS y Constancias/Dictámenes SEDUVI:** descarga del portal SEDUVI, normalización de clave de predio, carga en tabla individual_cus con campos: folio, fecha_emision, uso_autorizado, coeficiente_utilizacion, altura_maxima, vigencia; índice de texto sobre folio y spatial join a predio INEGI.
- **Zonificación ZEDEC:** polígonos por zona con CUS, altura máxima y restricciones de usos compatibles; join espacial a manzanas para asignar zonificacion_manzana como campo derivado.
- **Red peatonal OSM (ODbL):** descarga de extract CDMX vía Geofabrik, carga en pgRouting o OSRM local con topología de red; se valida conectividad del grafo (cero componentes desconectados en alcaldías target).

El padrón CUZUS merece tratamiento especial: los certificados tienen fecha de emisión y vigencia, y un predio puede tener constancias sucesivas de usos distintos. La tabla individual_cus almacena el historial completo y expone la constancia VIGENTE como vista materializada actualizable. Cuando existe más de una constancia vigente (caso de modificaciones parciales), se registra la más reciente como activa y se marca un flag de conflicto para revisión manual. Esta lógica es la base de la cascada de precedencia de E9.

El reloj regulatorio urbano es una tabla de metadatos: un registro por capa con campos (nombre_capa, fuente, fecha_descarga, fecha_vigencia_declarada, version_hash, observaciones). Cada script de carga inserta o actualiza este registro. En el futuro, una alerta automática se dispara cuando la fecha_vigencia_declarada de una capa supera N días sin actualización. La primera entrada corresponde al PGOT vigente con nota explícita de que el traductor de usos (equivalencia entre clasificación PGOT anterior y nueva) está marcado como pendiente de validación legal.

Restricción de licencia OSM

Los datos de OpenStreetMap se distribuyen bajo ODbL: cualquier base de datos derivada que se distribuya debe hacerse bajo la misma licencia. El grafo peatonal cargado en PostGIS es uso interno de CIMENTA y no se distribuye directamente, por lo que la ODbL no obliga a publicar la base. Sin embargo, si en el futuro se expone el grafo como API pública o se incluye en un entregable descargable, se debe aplicar la atribución y el share-alike. Esta restricción se registra como primera entrada del reloj regulatorio en la categoría "datos/consumidor".

El criterio de aceptación operacional de E6 es que el porcentaje de predios en alcaldías target con CUS asignado desde el padrón CUZUS/SEDUVI sea mayor o igual a 80%. Las alcaldías target iniciales son las 2-3 con mayor masa crítica de anuncios Nivel A; el porcentaje se calcula dividiendo predios con al menos una constancia CUZUS vigente entre el total de predios con geometría válida en esa alcaldía. Las alcaldías con cobertura menor a 80% se documentan y se marcan para estrategia alternativa (usar zonificación de manzana como fallback hasta obtener mejor cobertura del padrón).

TEST QUE DEBE PASAR

Los criterios de aceptación cubren cobertura geográfica, integridad de relaciones espaciales, calidad de geometrías y operabilidad del reloj regulatorio. Todos son verificables con consultas SQL sobre la base PostGIS resultante.

Prueba / verificación	Criterio de aprobación
Cobertura CUZUS en alcaldías target	>=80% de predios con geometría válida tienen al menos una constancia CUZUS vigente en cada alcaldía target; medido con COUNT sobre spatial join predio-constancia
Conectividad del grafo peatonal OSM	Cero componentes desconectados en el grafo pgRouting/OSRM dentro del polígono de cada alcaldía target; verificado con pgr_connectedComponents
Integridad de geometrías	Menos de 2% de geometrías inválidas en las tablas de manzanas, AGEs y predios tras ST_MakeValid; verificado con ST_IsValid
Cobertura DENUe geocruzada	>=95% de registros DENUe con coordenada asignada a una manzana INEGI dentro de las alcaldías target; medido con spatial join y COUNT de nulos
Reloj regulatorio inicializado	Tabla de reloj regulatorio con al menos 7 entradas (una por cada capa ingresada) con campos fecha_descarga, fecha_vigencia_declarada y version_hash no nulos
Script de actualización ejecutable	El script de re-ingesta de cada capa corre sin error en entorno limpio y actualiza el version_hash en el reloj regulatorio; validado con ejecución en entorno de staging
Índices espaciales presentes	EXPLAIN ANALYZE de ST_Within sobre manzanas INEGI devuelve Bitmap Index Scan (no Seq Scan) para consultas en una alcaldía target; tiempo de respuesta <500ms
Zonificación ZEDEC asignada	>=95% de manzanas en alcaldías target tienen campo zonificacion_manzana no nulo derivado del join espacial con polígonos ZEDEC; sin duplicados de manzana

Punto de control

>=80% de predios en alcaldías target con CUS desde padrón CUZUS/SEDUVI; grafo peatonal OSM enrutable; reloj regulatorio con primera entrada versionada. Si la cobertura CUZUS cae por debajo de 80% en las alcaldías target de arranque, se documenta la brecha y se diseña la estrategia de fallback antes de avanzar a E9.

QUÉ PASA CUANDO ESTA ETAPA ESTÁ LISTA

E6 desbloquea cuatro etapas dependientes. **E7** (spiders Scrapy) necesita la base PostGIS levantada para almacenar anuncios crudos y ejecutar el primer snap de coordenadas en prueba. **E9** (geocodificación) depende directamente de las capas de predios, manzanas y padrón CUZUS para ejecutar el snap y la cascada de

precedencia. **E18** (capa urbana completa) toma como insumo las capas SEDUVI/ZEDEC cargadas aquí para construir el CUS efectivo con cascada completa. **E19** (isócronas peatonales con barreras) requiere el grafo OSM en pgRouting/OSRM. En síntesis: sin E6 no existe el esqueleto sobre el que todo el stack de modelos y el motor de oportunidades opera; es la fundación geoespacial del producto.

07 PoC scraping Nivel A: portales con acuerdo o datos abiertos

FICHA TÉCNICA

Bloque	Ingesta y datos
Duración estimada	2 semanas
Dependencias	Etapa 1, Etapa 2 (dictamen de ToS por portal), Etapa 6 (PostGIS levantado)
Entregable principal	Spiders Scrapy funcionales para los portales Nivel A; primera corrida con $\geq 15,000$ anuncios crudos de casas, departamentos y terrenos en venta en alcaldías target CDMX; reporte de tasa de éxito por portal, campos extraídos y tasa de campos vacíos.
Punto de control / gate	$\geq 15,000$ anuncios crudos en DB; tasa de extracción exitosa $\geq 95\%$ en corrida semanal simulada; ningún spider evade medidas tecnológicas (Turnstile, JS-challenge) sin acuerdo previo.

QUÉ ES

La Etapa 7 construye los spiders Scrapy para los portales clasificados como **Nivel A**: aquellos que permiten el scraping según su robots.txt y ToS, o con los que existe un acuerdo de sindicación en trámite validado por el dictamen legal de E2. El objetivo es obtener la primera corrida real de anuncios crudos: casas, departamentos y terrenos en venta en las alcaldías target de CDMX, con volumen mínimo de 15,000 anuncios únicos y tasa de extracción exitosa de al menos 95%. El pipeline incluye rate limiting respetuoso, logging de errores por campo, manejo de cambios de estructura HTML y un esquema de almacenamiento crudo en PostgreSQL que preserva el HTML original para re-procesamiento. La etapa opera estrictamente dentro de los portales autorizados; no implementa ninguna técnica de evasión de Turnstile, JS-challenge de Cloudflare ni CAPTCHA.

QUÉ RESUELVE

El jurado señaló dos riesgos opuestos en el scraping: el riesgo legal de evadir medidas tecnológicas (art. 211 bis CPF y competencia desleal) y el riesgo de negocio de tener volumen insuficiente para calibrar el AVM. Esta etapa resuelve el segundo sin incurrir en el primero. La restricción de "solo Nivel A, sin evasión" no es una limitación de ingeniería sino una decisión de riesgo deliberada: el dictamen de E2 establece que la evasión de Turnstile configura acceso no autorizado, independientemente del uso posterior de los datos. La tasa de 95% mide la robustez del pipeline ante cambios de estructura del portal (el escenario de fracaso más frecuente en producción), no la capacidad de pasar barreras. El volumen de 15,000 anuncios es el piso mínimo para estimar la distribución de precios por segmento-colonia con intervalo de confianza útil.

DESCRIPCIÓN DETALLADA

Los spiders se desarrollan con Scrapy 2.x y se estructuran en tres capas: (1) el spider de extracción de URLs de listado (paginación), (2) el spider de extracción de campos por anuncio individual, y (3) el middleware de rate limiting y logging. Cada spider tiene un item schema fijo con los campos mínimos requeridos: url_fuente, id_portal, fecha_scrape, titulo, precio_anunciado, moneda, tipo_inmueble, superficie_construida_m2, superficie_terreno_m2, recamaras, banos, estacionamientos, alcaldia_declarada, colonia_declarada, direccion_texto, descripcion_larga, fotos_urls (lista), lat_declarada, lon_declarada. Los campos faltantes se registran como None con un flag de campo_vacio para medir la tasa de completitud por campo y por portal.

Capa del pipeline	Tecnología	Parámetro clave	Condición de fracaso
Extracción de listados	Scrapy Spider + CSS/XPath	Delay entre requests: 2-5 s aleatorio	Error HTTP 429 consecutivo por >10 min
Extracción de anuncio individual	Scrapy Item Pipeline	Timeout por anuncio: 30 s	>5% de anuncios con precio None
Rate limiting	AutoThrottle + AUTOTHROT-TLE_TARGET_CONCURRENCY	Concurrencia máxima 1 por dominio	Ban de IP detectado (HTTP 403 persistente)
Almacenamiento crudo	PostgreSQL tabla raw_listings	Inserción idempotente por (url_fuente, fecha_scrape)	Duplicados por clave primaria (indica bug de dedup temprano)
Logging de campos	Scrapy Item Pipeline custom	Registro de tasa de nulos por campo	Tasa de campos vacíos >20% en campo crítico (precio, superficie)
Manejo de cambios de estructura	Fallback CSS selector alternativo + alerta Slack	Tolerancia a 2 selectores alternativos	Tasa de extracción cae <90% en 2 corridas consecutivas

La decisión de NO evadir medidas tecnológicas implica que si un portal Nivel A activa Turnstile o un JS-challenge en el periodo entre E1 y E7, ese portal se reclasifica a Nivel B y sale del scope de esta etapa. El spider de ese portal se suspende, se documenta el cambio en el reloj regulatorio (campo: cambio_proteccion_portal) y se inicia el proceso de negociación de E8. Esta reclasificación es un evento esperado (los portales actualizan sus medidas); el pipeline debe detectarlo automáticamente comparando la tasa de extracción de la corrida actual contra el baseline de la corrida anterior.

El esquema de almacenamiento crudo preserva el HTML completo del anuncio en un campo bytea (comprimido con LZ4) para permitir re-procesamiento cuando el item schema evoluciona. La tabla raw_listings tiene particionamiento por portal y por semana de scrape. Esto permite invalidar el re-procesamiento de un portal específico sin tocar el resto, y facilita el cálculo de la tasa de anuncios nuevos vs actualizados vs eliminados en cada corrida (métrica del dashboard de E12).

Principio de no-evasión

El art. 211 bis CPF tipifica el acceso no autorizado a sistemas de cómputo. Evadir Turnstile o un JS-challenge de Cloudflare, aunque el portal no lo comunique explícitamente, puede interpretarse como acceso no autorizado cuando los ToS prohíben el scraping automatizado. El dictamen de E2 es el único respaldo legal de cada spider; si el dictamen no cubre un portal, ese spider no se desarrolla. Esta restricción no es opcional ni se negocia internamente.

La primera corrida de producción se ejecuta en un rango de 5-7 días para simular la cadencia semanal real. El reporte de resultados incluye: total de anuncios crudos obtenidos, distribución por portal y por alcaldía, tasa de campos vacíos por campo y por portal, y el log de errores HTTP clasificados por código. Si la tasa global de extracción exitosa cae por debajo de 95%, se hace diagnóstico por portal: un portal con tasa <90% activa alerta inmediata; un portal con tasa entre 90% y 95% entra en vigilancia con revisión manual del selector.

TEST QUE DEBE PASAR

Los criterios de aceptación cubren volumen, calidad de extracción y cumplimiento del principio de no-evasión. Todos son verificables contra la base de datos y los logs de la corrida de prueba.

Prueba / verificación	Criterio de aprobación
Volumen mínimo de anuncios crudos	$\geq 15,000$ anuncios únicos (url_fuente distinta) en DB al finalizar la corrida semanal simulada; medido con COUNT DISTINCT sobre raw_listings
Tasa de extracción exitosa global	$\geq 95\%$ de URLs de anuncios individuales visitadas resultan en un ítem con precio no nulo; calculado como $(\text{items_con_precio} / \text{urls_visitadas}) \times 100$
Tasa de campos críticos	Precio y tipo_inmueble con tasa de nulos $< 5\%$ por portal; superficie_construida_m2 con tasa de nulos $< 20\%$ (los terrenos no la declaran); medido por portal
Cobertura geográfica mínima	Anuncios presentes en las 3 alcaldías target con al menos 500 anuncios únicos por alcaldía; distribución documentada en reporte
Sin evasión de medidas tecnológicas	Auditoría de logs HTTP: cero requests a endpoints de resolver de CAPTCHA externos, cero uso de servicios de rotación de fingerprint de navegador, cero ejecución de JavaScript headless para pasar challenges; verificado por el cofundador técnico en revisión de código
Detección de cambio de estructura	El middleware de alerta se dispara correctamente cuando la tasa de extracción de un portal cae > 5 puntos porcentuales en comparación con la corrida anterior; probado con un mock de selector roto
Idempotencia de inserción	Re-ejecutar el spider sobre las mismas URLs no duplica registros en raw_listings; verificado con (url_fuente, fecha_scrape) como clave única
Preservación del HTML crudo	100% de anuncios extraídos tienen campo html_raw no nulo; el HTML permite re-extraer el precio con el selector original en re-procesamiento manual

Punto de control

$\geq 15,000$ anuncios crudos en DB; tasa de extracción exitosa $\geq 95\%$ en corrida semanal simulada; ningún spider evade medidas tecnológicas. Si el volumen cae por debajo de 15,000 o la tasa baja de 95%, se diagnostica por portal antes de avanzar. Si la tasa cae por evasión involuntaria de una medida no documentada, el spider se suspende y se solicita actualización del dictamen de E2.

QUÉ PASA CUANDO ESTA ETAPA ESTÁ LISTA

E7 desbloquea directamente E9 (geocodificación) y E10 (deduplicación), que requieren el corpus de anuncios crudos para ejecutar sus pipelines. También es insumo de E11 (enriquecimiento LLM) y E12 (orquestración semanal). De forma indirecta, el volumen y calidad de los anuncios de E7 determinan si el AVM de E15 tiene soporte estadístico suficiente por celda: si una alcaldía queda con menos de 500 anuncios únicos, el AVM activa el gate de abstención condicional para esa celda. El reporte de cobertura de E7 es el insumo para que E8 priorice qué portales Nivel B negociar con mayor urgencia.

08 Negociación de acuerdos de sindicación con portales Nivel B prioritarios

FICHA TÉCNICA

Bloque	Ingesta y datos
Duración estimada	4 semanas (paralelo a etapas 7 y 9)
Dependencias	Etapas 1, Etapa 2
Entregable principal	Cartas de intención o acuerdos de piloto con al menos 1 portal Nivel B; plan de contingencia documentado con las 2-3 alcaldías de arranque seguro si no se concretan acuerdos; piso de celdas accionables definido (cuántas celdas segmento-zona necesitan cierres para que el negocio sea servible).
Punto de control / gate	Al menos 1 acuerdo de sindicación firmado o en fase final de negociación, O decisión documentada de arrancar v0 con cobertura reducida y declaración pública del alcance real por alcaldía.

QUÉ ES

La Etapa 8 es la etapa de posicionamiento estratégico frente a los portales de mayor volumen que no permiten scraping libre: los **Nivel B**. Implica iniciar negociaciones formales de data-partnership o sindicación con los 2-3 portales prioritarios, diseñar la propuesta de valor para el portal (enriquecimiento de sus propios listings, índices de mercado, visibilidad en informes CIMENTA), y ejecutar en paralelo la estrategia de contingencia si las negociaciones no concluyen en el plazo del roadmap. La estrategia de contingencia fija el **piso de celdas accionables**: cuántas celdas segmento-zona necesitan cierres observados para que el AVM produzca intervalos de ancho útil, y determina en cuáles 2-3 alcaldías el Nivel A más los acuerdos ya logrados dan masa crítica suficiente para lanzar v0 con cobertura reducida declarada públicamente.

QUÉ RESUELVE

El jurado identificó como riesgo de negocio de alta probabilidad que los portales Nivel B no acuerden en el tiempo esperado o impongan condiciones que hacen no viable la sindicación (exclusividad, precios prohibitivos, restricciones de uso). Esta etapa no resuelve ese riesgo eliminándolo sino dimensionándolo: si el acuerdo no llega, CIMENTA sabe exactamente en qué alcaldías puede operar con calidad suficiente y cuáles quedan fuera del scope de v0. El "piso de celdas accionables" es la métrica que convierte la incertidumbre de negociación en una decisión operacional concreta: no se anuncia cobertura que no existe, y el material de venta de E39 es honesto sobre el alcance geográfico real de v0.

DESCRIPCIÓN DETALLADA

La propuesta de valor para el portal parte de una asimetría: CIMENTA tiene capas de datos (INEGI, SEDUVI, OSM) que el portal no tiene, y el portal tiene volumen de listings que CIMENTA no puede obtener vía scraping libre. El intercambio natural es: acceso a feed de listings a cambio de enriquecimiento con capas de uso de suelo, zona geotécnica, isócrona peatonal y score de demanda por colonia. Este enriquecimiento mejora la calidad del listing para el usuario final del portal (más información por predio) y reduce el churn de anunciantes premium. Se preparan dos documentos para la reunión inicial: (1) una demo con 50 predios enriquecidos del propio portal, con capas superpuestas en mapa; (2) un term sheet borrador con las condiciones mínimas aceptables para CIMENTA (acceso semanal al feed completo de CDMX, formato JSON/CSV, sin exclusividad de CIMENTA hacia el portal, sin restricción de uso en entregables B2B).

- **Portales target Nivel B:** los 2-3 con mayor volumen estimado en CDMX según el análisis de E1; priorizar por brecha de cobertura respecto a Nivel A (cuántos anuncios únicos adicionales aportaría el acuerdo).
- **Propuesta de intercambio:** feed de listings a cambio de enriquecimiento con capas CIMENTA (uso de suelo, zona geotécnica, isócrona peatonal, score de demanda). Sin pago monetario en versión inicial; el valor es el enriquecimiento.
- **Term sheet mínimo aceptable:** acceso semanal al feed completo CDMX; formato estructurado JSON o CSV; sin cláusula de exclusividad de CIMENTA hacia el portal; sin restricción de uso analítico en entregables B2B; atribución de fuente en los entregables.
- **Plazo de negociación:** 4 semanas paralelas a E7 y E9; si no hay carta de intención al final de la semana 4, se activa el plan de contingencia documentado.
- **Plan de contingencia "dato raro":** identificar las 2-3 alcaldías donde Nivel A + acuerdos logrados producen al menos N anuncios únicos por celda segmento-zona (el piso de celdas accionables); declarar públicamente el alcance reducido; ajustar el material de venta de E39 para no prometer cobertura en alcaldías fuera del piso.

El **piso de celdas accionables** se define con un power analysis por celda: dada la varianza observada de precios en el corpus Nivel A, cuántos comparables vivos en una celda (segmento x colonia) producen un intervalo de predicción del AVM con ancho relativo menor a X% del V50. El umbral X es un parámetro de producto: se fija en función de qué nivel de incertidumbre hace que el intervalo sea "útil" para una decisión de compra de terreno de un ICP-1. Una celda con menos comparables que ese mínimo activa el gate de abstención del AVM para jugada A, y produce solo cotas orientativas para jugada C. El power analysis se corre sobre el corpus de E7 al finalizar la primera corrida real.

Escenario de negociación	Cobertura de v0	Impacto en AVM	Acción en material de venta
Acuerdo con 1 portal Nivel B	4-6 alcaldías con masa crítica	Gate de abstención activo en celdas ralas fuera del core	Declarar 4-6 alcaldías en el one-pager de E39
Sin acuerdo Nivel B	2-3 alcaldías con Nivel A solo	Gate de abstención activo en todo el scope fuera del core	Declarar 2-3 alcaldías; no prometer expansión sin acuerdo
Acuerdo con 2+ portales Nivel B	8-12 alcaldías con masa crítica	Gate activo solo en celdas micro-ralas	Alcance completo CDMX declarable con restricciones por colonia

La decisión documentada al finalizar E8 es vinculante para el material de ventas (E39), el TAM de E36, el modelo financiero de E37 y la cobertura declarada en el frontend de E33. No es posible comprometer cobertura mayor a la que el piso de celdas accionables valida. Si una constructora piloto opera principalmente en alcaldías fuera del piso, se le informa antes de firmar el MSA de E42.

Riesgo de negociación prolongada

Los ciclos de decisión de los portales inmobiliarios grandes pueden extenderse más de 4 semanas, especialmente si requieren aprobación legal interna. Si al finalizar la semana 4 no hay carta de intención, no se extiende el plazo de negociación bloqueando el roadmap: se activa el plan de contingencia y se continúa con las etapas siguientes sobre la cobertura reducida. La negociación puede continuar en paralelo, pero no es path-crítica para el lanzamiento de v0.

TEST QUE DEBE PASAR

Los criterios de aceptación validan tanto el avance en la negociación como la solidez del plan de contingencia. La etapa tiene éxito incluso si no se concreta ningún acuerdo, siempre que el plan alternativo esté documentado y el piso de celdas accionables esté calculado.

Prueba / verificación	Criterio de aprobación
Avance de negociación con portales Nivel B	Al menos 1 carta de intención firmada o reunión formal de negociación completada con cada portal Nivel B prioritario; evidencia documentada (acta o correo de confirmación)
Plan de contingencia documentado	Documento escrito con: lista de 2-3 alcaldías de arranque seguro, número de anuncios únicos esperados por alcaldía con solo Nivel A, piso de celdas accionables calculado, y declaración de alcance reducido para el material de ventas
Piso de celdas accionables calculado	Power analysis ejecutado sobre el corpus de E7: número mínimo de comparables por celda (segmento x colonia) que produce intervalo AVM con ancho relativo <X% del V50; X documentado como parámetro de producto con su justificación
Cobertura por alcaldía cuantificada	Tabla con: alcaldía, anuncios únicos Nivel A, anuncios adicionales esperados de cada acuerdo Nivel B, total estimado, y clasificación (sobre/bajo el piso de celdas accionables)
Propuesta de valor entregada a portales	Demo de enriquecimiento con 50 predios reales del portal preparada y enviada a al menos 2 portales Nivel B; evidencia de recepción
Term sheet borrador disponible	Term sheet con condiciones mínimas aceptables para CIMENTA redactado y revisado por el asesor legal (mismas condiciones que el dictamen de E2 requiere para acuerdos de sindicación)

Punto de control

Al menos 1 acuerdo de sindicación firmado o en fase final de negociación, O decisión documentada de arrancar v0 con cobertura reducida y declaración pública del alcance real por alcaldía. El criterio de aceptación es que la decisión esté tomada y documentada; no es obligatorio haber firmado un acuerdo.

QUÉ PASA CUANDO ESTA ETAPA ESTÁ LISTA

E8 desbloquea la definición definitiva del scope de v0 en todas las etapas posteriores. El plan de contingencia de E8 es el insumo directo del TAM de E36 (cuántos clientes son alcanzables con la cobertura real), del modelo financiero de E37 (cuántos dossiers por mes se pueden generar), del frontend de E33 (qué alcaldías muestra el mapa), y del material de ventas de E39 (qué declara el one-pager sobre cobertura). Si hay acuerdo con un portal

Nivel B, el feed de datos entra al pipeline de E12 como una fuente adicional con su propio spider o conector. Si no hay acuerdo, el lanzamiento de v0 ocurre con la cobertura reducida declarada: esta es una condición de fracaso aceptable del plan, no del negocio.

09 Pipeline de geocodificación y normalización de direcciones

FICHA TÉCNICA

Bloque	Ingesta y datos
Duración estimada	2 semanas
Dependencias	Etapas 6, 7
Entregable principal	Pipeline de geocodificación productivo con tasa de geocodificación $\geq 90\%$ a nivel colonia y $\geq 70\%$ a nivel predio sobre los anuncios de la corrida de prueba; campo de CUS asignado con fuente y bandera 'uso individual divergente de manzana' cuando aplique; zona geotécnica y coeficiente sísmico por predio asignados.
Punto de control / gate	$\geq 90\%$ de anuncios geocodificados a nivel colonia; CUS asignado con cascada de precedencia documentada; bandera de 'uso individual divergente' presente en los predios que la tienen según padrón CUZUS.

QUÉ ES

La Etapa 9 construye el pipeline de geocodificación y normalización de direcciones que convierte el texto libre de cada anuncio crudo en una coordenada válida anclada a la geometría del padrón oficial. El proceso tiene cinco pasos secuenciales: (1) normalización del texto de dirección (alcaldía, colonia, calle, número); (2) geocodificación vía Nominatim/OSM con fallback a DENUE/INEGI; (3) snap al predio o manzana INEGI más cercano; (4) asignación de CUS desde la **cascada de precedencia** (constancia individual SEDUVI > instrumento de actuación > zonificación de manzana > PGOT-traductor); (5) asignación de zona geotécnica NTC-Cimentaciones 2023 y periodo de suelo por coordenada. El resultado es un anuncio con clave_predio_inegi, CUS efectivo con fuente de precedencia, zona geotécnica (I lomas / II transición / III lago) y un flag de "uso individual divergente de manzana" cuando la constancia SEDUVI de ese predio difiere del uso general de su manzana.

QUÉ RESUELVE

Sin geocodificación robusta, el AVM no puede construir features de localización (distancia a transporte, isócrona peatonal, zona geotécnica) y el CUS efectivo queda sin asignar, lo que hace imposible el cálculo de potencial constructivo de jugada C. El riesgo de negocio es doble: un predio mal geocodificado (snap erróneo a manzana incorrecta) recibe el CUS de la manzana equivocada y genera una pro-forma incorrecta; un predio correctamente geocodificado pero con CUS de manzana cuando existe una constancia individual divergente subestima o sobreestima el potencial real. La cascada de precedencia resuelve el segundo riesgo de forma sistemática. El flag de "uso individual divergente" permite al cliente saber cuándo el CUS de manzana no aplica a ese predio específico, y es una alerta de due diligence.

DESCRIPCIÓN DETALLADA

La normalización de texto es el primer filtro de calidad. Los anuncios usan abreviaturas, errores ortográficos y formatos inconsistentes: "Col.", "Colonia", "col", sin colonia, con solo referencia de cruce. Se construye un normalizador basado en diccionarios de colonias INEGI (catálogo oficial) con fuzzy matching (rapidfuzz, umbral de similitud ajustable por alcaldía): si la colonia declarada en el anuncio no coincide exactamente con ninguna del catálogo, se toma la más similar con score $\geq$ umbral y se registra el score de confianza. Los anuncios con score de normalización de colonia por debajo del umbral mínimo se marcan como "colonia_no_resuelta" y se geocodifican solo a nivel alcaldía.

- **Paso 1 - Normalización:** diccionarios de colonias/alcaldías INEGI + rapidfuzz; se registra score de confianza y versión del diccionario; anuncios con score $<$ umbral se marcan "colonia_no_resuelta".
- **Paso 2 - Geocodificación primaria:** Nominatim sobre instancia local de OSM CDMX (para evitar rate limits de la API pública); query estructurada con (calle, número, colonia_normalizada, alcaldía, CDMX); se registra el bounding box de confianza de Nominatim.
- **Paso 2b - Fallback DENUÉ/INEGI:** si Nominatim no resuelve a nivel calle/número, se busca la dirección en DENUÉ (por nombre de vía y colonia); si tampoco, se toma el centroide de la colonia INEGI como coordenada de fallback; se registra la fuente de geocodificación y el nivel de precisión (predio/calle/colonia/alcaldía).
- **Paso 3 - Snap a predio/manzana:** ST_ClosestPoint de la coordenada geocodificada contra la tabla de predios INEGI (tolerancia máxima: 50 m); si el predio más cercano supera la tolerancia, snap a manzana con la misma tolerancia; si supera la tolerancia de manzana, se queda con la coordenada geocodificada sin snap y se registra "sin_snap_oficial".
- **Paso 4 - Cascada de precedencia CUS:** (a) si existe constancia individual SEDUVI vigente para esa clave_predio: se usa su uso_autorizado; (b) si el predio cae en un polígono de instrumento de actuación (SAC, DOT, corredor de incentivos) con CUS propio: se usa el del instrumento; (c) si no aplica ninguno: se usa la zonificacion_manzana de la capa ZEDEC; (d) si la manzana no tiene ZEDEC asignado: se usa el PGOT-traductor marcado como "intervalo abierto / pendiente de validación legal".
- **Paso 5 - Zona geotécnica y periodo de suelo:** join espacial contra la capa NTC-Cimentaciones 2023 (tres zonas: I lomas, II transición, III lago); asignación del periodo de suelo Ts por subzona donde esté disponible; campo zona_geotecnica y periodo_suelo_s en la tabla de anuncios normalizados.

El flag "uso_individual_divergente" se activa cuando la fuente de precedencia del CUS es la constancia individual SEDUVI (paso 4a) Y el uso_autorizado de esa constancia difiere del uso general de la manzana según ZEDEC. Este flag es crítico para el ICP-1: un predio con uso individual divergente puede tener un potencial constructivo mayor al que indica su manzana (constancia que ya autorizó un uso más intensivo) o menor (constancia que restringe un uso que la manzana permitiría). El flag se incluye en la ficha del anuncio y en el dossier de jugada C.

La tasa de geocodificación se mide en tres niveles de precisión: nivel predio (snap exitoso a la tabla de predios INEGI), nivel colonia (snap a centroide de colonia INEGI), y nivel alcaldía (solo el centroide de la alcaldía). La meta de E9 es $\geq 90\%$ a nivel colonia y $\geq 70\%$ a nivel predio. Las alcaldías con tasas de geocodificación por debajo de estos umbrales se documentan: generalmente corresponden a colonias informales con numeración irregular o zonas con cobertura OSM incompleta. Para esas zonas, el pipeline activa la regla de abstención del AVM: no emite V50 ni jugada C sin una coordenada con precisión mínima de colonia.

Analogía del reloj de precedencia

La cascada de precedencia funciona como un reloj de capas superpuestas: la aguja más corta es la zonificación de manzana (la regla general), la siguiente es el instrumento de actuación (la excepción de polígono), y la más larga y precisa es la constancia individual SEDUVI (la excepción de predio). Cuando existen las dos agujas más largas, las más cortas son irrelevantes. Cuando solo existe la más corta, es la mejor información disponible pero con mayor incertidumbre. El PGOT-traductor es la caja de seguridad: cuando no hay ninguna aguja, se reporta el rango de interpretación como intervalo abierto, nunca como un valor puntual.

El pipeline se implementa como un DAG de transformación en Python con pasos atómicos e idempotentes: cada paso puede re-ejecutarse de forma independiente sin alterar los resultados de pasos anteriores si los datos de entrada no cambiaron. Se usa un hash del anuncio crudo como clave de idempotencia: si el HTML crudo de un anuncio no cambió respecto a la semana anterior, los pasos 1-5 no se re-ejecutan y se reutiliza el resultado previo. Solo los anuncios nuevos o modificados pasan por el pipeline completo.

TEST QUE DEBE PASAR

Los criterios de aceptación verifican cobertura de geocodificación, corrección de la cascada de precedencia, y presencia de los campos derivados en la tabla de anuncios normalizados. Las tasas se calculan sobre el corpus completo de la primera corrida de E7.

Prueba / verificación	Criterio de aprobación
Tasa de geocodificación a nivel colonia	>=90% de anuncios del corpus de E7 con campo colonia_geocodificada no nulo y nivel_precision en ('predio', 'calle', 'colonia'); medido con COUNT por nivel sobre el corpus completo
Tasa de geocodificación a nivel predio	>=70% de anuncios con snap exitoso a la tabla de predios INEGI (tolerancia <=50 m); medido con COUNT de registros con clave_predio_inegi no nulo
CUS asignado con cascada de precedencia	>=95% de anuncios geocodificados a nivel predio o colonia tienen campo cus_efectivo no nulo y campo fuente_precedencia con valor en ('constancia_seduvi', 'instrumento_actuacion', 'zonificacion_manzana', 'pgot_traductor')
Flag de uso individual divergente	El flag uso_individual_divergente se activa correctamente en al menos 10 predios conocidos con constancia SEDUVI divergente (validado manualmente contra el padrón CUZUS cargado en E6)
Zona geotécnica asignada	>=95% de anuncios geocodificados a nivel predio o colonia tienen campo zona_geotecnica no nulo con valor en ('I', 'II', 'III'); medido con COUNT de nulos sobre el corpus
Idempotencia del pipeline	Re-ejecutar el pipeline sobre el mismo corpus de entrada produce resultados bit-a-bit idénticos en las tablas de salida; verificado comparando hashes de tablas antes y después de segunda ejecución
Fallback documentado	100% de anuncios con nivel_precision = 'alcaldia' tienen campo fuente_geocodificacion = 'centroide_alcaldia' y el campo sin_snap_oficial = True; no se emite CUS puntual para estos anuncios
Tiempo de procesamiento por lote	El pipeline completo de los 15,000 anuncios de E7 corre en menos de 4 horas en el entorno de staging; documentado para dimensionar el SLA de E12

Punto de control

>=90% de anuncios geocodificados a nivel colonia; CUS asignado con cascada de precedencia documentada; flag de uso individual divergente presente en los predios que la tienen según padrón CUZUS. Si la tasa de geocodificación a nivel colonia cae por debajo de 90% en alguna alcaldía target, se diagnostica la causa (cobertura OSM, numeración irregular) y se diseña estrategia de mejora antes de avanzar al AVM.

QUÉ PASA CUANDO ESTA ETAPA ESTÁ LISTA

E9 desbloquea E10 (deduplicación), que necesita las coordenadas normalizadas y la clave_predio_inegi como parte del bloqueo geo+superficie. También desbloquea E11 (enriquecimiento LLM) y E13 (panel-semilla de cierres). De forma crítica, la cascada de precedencia y el flag de uso individual divergente son inputs directos de E18 (capa urbana completa) y del motor de jugada C en E25. Sin E9, el motor no puede calcular el potencial constructivo con la fuente de precedencia correcta por predio.

10 Deduplicación: golden set, métricas y pipeline productivo

FICHA TÉCNICA

Bloque	Ingesta y datos
Duración estimada	3 semanas
Dependencias	Etapa 7, Etapa 9
Entregable principal	Golden set de 500+ pares etiquetados con subconjunto HARD; modelo de deduplicación productivo con precisión global ≥ 0.98 y recall global ≥ 0.95 (con intervalos de confianza); precisión operativa ajustada a prevalencia real; objetivos de falso-merge y falso-split por 1,000 comparables vivos con sus costos asimétricos documentados; n_{efectivo} probabilístico calculado por cluster con su varianza.
Punto de control / gate	Precisión ≥ 0.98 y recall ≥ 0.95 globales validados sobre golden set; precisión del subconjunto HARD documentada por separado; n_{efectivo} probabilístico alimentando el gate de abstención del AVM.

QUÉ ES

La Etapa 10 construye el pipeline de deduplicación que identifica cuándo dos o más anuncios de distintos portales corresponden al mismo predio físico, y calcula el número efectivo de propiedades únicas en el mercado como una **distribución probabilística**, no como un conteo entero. El pipeline opera en tres capas: (1) **bloqueo** por geo+superficie para reducir el espacio de comparación; (2) **decisión** por embeddings de texto (similitud semántica) y hash perceptual de imágenes (robusto a recompresión y marcas de agua), con regla anti-falso-positivo para fotos de catálogo y áreas comunes compartidas; (3) **soft-clustering** con probabilidades de pertenencia para calcular n_{efectivo} probabilístico con varianza. El pipeline se valida contra un **golden set de 500+ pares** estratificados por dificultad, con un subconjunto HARD obligatorio de los cuatro tipos de error más difíciles.

QUÉ RESUELVE

La deduplicación es la diferencia entre un AVM que observa la distribución real del mercado y uno que ve el mercado inflado por re-publicaciones del mismo predio en múltiples portales. Sin deduplicación robusta, el n_{efectivo} de comparables en una celda está sobreestimado, el intervalo de predicción del AVM es artificialmente estrecho (falsa precisión), y el motor de jugada A puede recomendar una "oportunidad de subvaluación" que en realidad es el mismo predio publicado dos veces a precios distintos. El jurado identificó como costos asimétricos: un **falso-merge** (dos predios distintos tratados como uno) infla el n_{efectivo} reportado → el AVM sobre-publica confianza → riesgo de acción sobre falsa señal. Un **falso-split** (el mismo predio tratado como dos) deflacta el n_{efectivo} → el AVM sobre-abstiene → pérdida de oportunidades reales. Ambos errores tienen consecuencias distintas para el negocio y se reportan por separado.

DESCRIPCIÓN DETALLADA

El **bloqueo geo+superficie** reduce el espacio de comparación de $O(n^2)$ a un conjunto manejable. Se genera un índice de bloques usando (celda_geo_500m x bin_superficie_10m2): solo se comparan pares dentro del mismo bloque. El tamaño del bloque se calibra para que el recall del bloqueo (fracción de pares verdaderos que caen en el mismo bloque) sea $\geq 99.5\%$; si el bloqueo pierde un par verdadero, ese error no puede recuperarse en pasos posteriores. La superficie usada para el bloqueo es la superficie_construida_m2 del anuncio normalizada al bin más cercano; los terrenos sin superficie construida usan solo el bloque geo.

- **Capa 1 - Bloqueo geo+superficie:** grilla hexagonal H3 resolución 9 (aprox. 0.1 km^2) + bin de superficie_construida_m2 de ancho 10 m2; solo se comparan pares en el mismo bloque; recall del bloqueo $\geq 99.5\%$ validado en el golden set.
- **Capa 2a - Embeddings de texto:** modelo sentence-transformer multilingüe (ej. paraphrase-multilingual-mpnet-base-v2 o equivalente) sobre (titulo + descripcion_larga normalizada); similitud coseno con umbral ajustable; se registra el score de similitud como feature continuo.
- **Capa 2b - Hash perceptual de imágenes:** pHash o dHash sobre cada imagen del anuncio; comparación de Hamming distance con umbral; robusto a recompresión JPEG y marcas de agua superpuestas (validado en el golden set con pares HARD de misma foto comprimida distinto portal).
- **Regla anti-falso-positivo para fotos de catálogo:** las imágenes de amenidades compartidas (alberca, lobby, gym) son idénticas entre anuncios de distintas unidades del mismo edificio; se detectan por frecuencia de aparición en el corpus (si una imagen aparece en $>K$ anuncios distintos, se excluye de la comparación de identidad).
- **Capa 3 - Soft-clustering:** modelo probabilístico (ej. probabilistic record linkage o un clasificador binario con salida de probabilidad calibrada) que asigna a cada par un $P(\text{misma_unidad})$; se construyen clusters de anuncios con probabilidades de pertenencia; n_{efectivo} del cluster = suma de probabilidades de pertenencia, no el conteo de anuncios.
- **n_{efectivo} probabilístico:** para un cluster de 3 anuncios con probabilidades $[0.95, 0.90, 0.30]$, $n_{\text{efectivo}} = 1 + (1-0.95) + (1-0.90) + (1-0.30) = 1 + 0.05 + 0.10 + 0.70 = 1.85$; la varianza de n_{efectivo} se calcula por propagación y se reporta junto con la estimación.

El **golden set de 500+ pares** es el activo de validación más crítico de esta etapa. Se construye manualmente con cuatro estratos de dificultad:

Tipo de par HARD	Por qué es difícil	Riesgo si se falla	N mínimo en golden set
Mismo predio, fotos distintas (distinto portal, distinta fecha de publicación)	Los embeddings de imagen no coinciden; el texto puede variar ligeramente	Falso-split: el AVM ve 2 comparables en vez de 1	50 pares
Predios distintos en mismo edificio (depto A vs depto B, misma torre)	Las fotos de amenidades y el texto de descripción del edificio son casi idénticos	Falso-merge: el AVM colapsa dos unidades reales en una	80 pares
Terreno vs construcción en el mismo predio (terreno publicado luego re-publicado como proyecto)	Superficie_construida es distinta pero el terreno y la ubicación son idénticos	Falso-merge: mezcla de segmentos que no son comparables	40 pares
Falso-split por variación de precio (mismo anuncio republicado con precio actualizado)	El HTML es casi idéntico pero la fecha y el precio cambiaron; el id_portal puede ser diferente	Falso-split: el AVM ve una baja de precio como dos comparables distintos	60 pares

Las métricas de validación se reportan en **dos capas**: métricas globales (precisión ≥ 0.98 , recall ≥ 0.95 sobre los 500+ pares) y métricas del subconjunto HARD por separado (con sus propios umbrales documentados, que

pueden ser más bajos). La precisión operativa se ajusta a la **prevalencia real** de duplicados en el corpus productivo: si la tasa real de duplicados en el mercado es del 30% (estimada en E7), la precisión ajustada a prevalencia puede diferir significativamente de la precisión global del golden set (que está estratificado, no refleja la prevalencia natural). Esta distinción es crítica para no sobre-estimar la precisión operacional.

Costos asimétricos de los errores

Falso-merge (precisión baja): une dos predios distintos → n_{efectivo} sobreestimado → el AVM reporta más soporte del real → intervalos artificialmente estrechos → sobre-publica confianza en celdas con poco soporte real. Falso-split (recall bajo): separa el mismo predio en dos → n_{efectivo} subestimado → el AVM activa abstención en celdas que realmente tienen soporte → sobre-abstiene → el cliente no ve oportunidades reales. El balance entre los dos errores se define como parámetro de producto, no como decisión técnica autónoma: debe documentarse explícitamente con qué umbral de probabilidad se prefiere cada dirección de error según el impacto en el negocio.

El n_{efectivo} probabilístico no es un número entero sino una distribución; su varianza alimenta el **gate de abstención del AVM de E15**: si la varianza de n_{efectivo} en una celda es alta (el pipeline no sabe bien cuántos comparables únicos hay), el AVM ensancha el intervalo de predicción o activa la abstención. Este encadenamiento hace de E10 una dependencia crítica de calidad del AVM, no solo de volumen.

TEST QUE DEBE PASAR

Los criterios de aceptación cubren las métricas globales del golden set, las métricas del subconjunto HARD por separado, la precisión ajustada a prevalencia, y la operabilidad del n_{efectivo} probabilístico como input del AVM. Todas las métricas se calculan con intervalos de confianza bootstrapeados ($n=1000$ muestras).

Prueba / verificación	Criterio de aprobación
Precisión global sobre golden set	Precisión ≥ 0.98 sobre el golden set completo de 500+ pares; intervalo de confianza 95% bootstrapeado reportado; medido con threshold de probabilidad fijado en la calibración
Recall global sobre golden set	Recall ≥ 0.95 sobre el golden set completo; intervalo de confianza 95% bootstrapeado reportado; threshold de probabilidad fijado en la calibración
Métricas del subconjunto HARD por separado	Precisión y recall del subconjunto HARD (los 4 tipos de par difícil) reportados por separado con sus propios IC; si algún tipo cae por debajo de un umbral documentado, se registra como hallazgo y se discute el trade-off con el equipo de producto
Precisión ajustada a prevalencia real	Precisión operativa calculada con la prevalencia estimada de duplicados en el corpus productivo (estimada en E7); documentada como métrica separada de la precisión del golden set estratificado; diferencia entre ambas reportada
Recall del bloqueo geo+superficie	El paso de bloqueo captura $\geq 99.5\%$ de los pares verdaderos del golden set en el mismo bloque; medido como fracción de pares positivos del golden set que caen en bloques compartidos
Regla anti-falso-positivo de fotos de catálogo	Las imágenes de amenidades compartidas (frecuencia $>K$ en el corpus) no contribuyen a clasificar un par como duplicado; verificado con los 80 pares "predios distintos en mismo edificio" del golden set HARD
n_efectivo probabilístico calculado por cluster	100% de clusters de anuncios tienen campo n_efectivo (float) y n_efectivo_varianza (float) no nulos; n_efectivo es siempre $\leq n_{\text{anuncios del cluster}}$ y ≥ 1.0 para clusters con al menos 1 anuncio con $P(\text{misma_unidad})=1$
n_efectivo alimentando el gate de abstención del AVM	El campo n_efectivo_varianza es accesible en el feature store de E15 y el gate de abstención del AVM cambia de estado correctamente cuando n_efectivo_varianza supera el umbral configurado; verificado con una celda mock con varianza alta

Punto de control

Precisión ≥ 0.98 y recall ≥ 0.95 globales validados sobre golden set con IC bootstrapeados; precisión del subconjunto HARD documentada por separado; n_efectivo probabilístico calculado por cluster y alimentando el gate de abstención del AVM. Si las métricas HARD caen significativamente por debajo de las globales para algún tipo de par, se decide explícitamente si se acepta el trade-off o se invierte en mejora del modelo antes de avanzar al AVM.

QUÉ PASA CUANDO ESTA ETAPA ESTÁ LISTA

E10 desbloquea E11 (enriquecimiento LLM), que opera sobre el corpus deduplicado (no sobre anuncios crudos), y E12 (orquestración semanal), que necesita el n_efectivo probabilístico como métrica del dashboard. De forma crítica, el n_efectivo probabilístico es el input del **gate de abstención del AVM de E15**: sin E10, el AVM no puede saber cuántos comparables únicos reales tiene en cada celda y no puede distinguir entre una celda con soporte real y una con muchos anuncios del mismo predio. El golden set de E10 también sirve como referencia para el golden set de deduplicación dentro del corpus de obra nueva en E22.