




Plan maestro de producto: plataforma de detección de oportunidades inmobiliarias en México

De los datos crudos de diez portales a un portafolio óptimo de inversión:
valuación automática, plusvalía predictiva, uso de suelo y conectividad urbana.



CIMENTA

Inteligencia inmobiliaria cuantitativa

*“El mercado inmobiliario mexicano publica sus precios todos los días.
Nadie los está leyendo todos a la vez. Nosotros sí.”*

Misión

Convertir la opacidad del mercado inmobiliario mexicano en decisiones de inversión medibles, comparables y auditables, poniendo herramientas de nivel institucional en manos de inversionistas individuales.

Visión

Ser el estándar de referencia en valuación y detección de oportunidades inmobiliarias en América Latina: el lugar donde una persona con capital pregunta “¿dónde invierto?” y recibe una respuesta cuantitativa, no una corazonada.

Valores

Rigor antes que retórica.

Cada recomendación lleva un número, un intervalo de confianza y la evidencia que la sustenta.

Transparencia del modelo.

Si el sistema dice “compra”, el usuario puede ver por qué: comparables, supuestos y sensibilidad.

Datos con ética.

Recolectamos solo información pública, respetamos términos de uso y privacidad, y declaramos las limitaciones.

Minimalismo funcional.

Menos pantallas, menos adornos, más señal. El producto se mide en decisiones correctas, no en clics.

Humildad estadística.

Los modelos se equivocan; los nuestros saben cuánto y lo dicen.

Índice

1	Resumen ejecutivo	7
1.1	Qué construiremos	7
1.2	Por qué ahora	8
1.3	Cifras objetivo del plan	8
1.4	Estructura de este documento	8
2	Identidad: la marca CIMENTA	9
2.1	El nombre	9
2.2	El logotipo	9
2.3	Paleta de color	9
2.4	Tipografía y tono	10
2.5	Principios de diseño de producto	10
3	El mercado y el problema	11
3.1	El problema en una imagen	11
3.2	Asimetrías que generan la oportunidad	11
3.3	A quién servimos	12
3.4	Ámbito geográfico inicial	12
4	Arquitectura general del sistema	13
4.1	Vista de pájaro	13
4.2	Decisiones de arquitectura	14
4.3	El esquema de datos central	14
5	Módulo 1 — Ingesta: los diez portales	16

5.1	El universo de fuentes	16
5.2	Arquitectura de recolección	16
5.2.1	Patrón general por portal	17
5.2.2	Deduplicación: el problema central	17
5.2.3	Enriquecimiento con LLM	17
5.2.4	Geocodificación y asignación de colonia	18
5.3	Frecuencia, volumen y monitoreo	18
6	Módulo 2 — AVM: cuánto debería valer cada propiedad	19
6.1	Definición del problema	19
6.2	La variable objetivo y su trampa	19
6.3	Arquitectura del modelo	19
6.3.1	Modelo hedónico base (interpretable)	20
6.3.2	Modelo de producción (gradient boosting espacial)	20
6.3.3	Incertidumbre: el intervalo importa más que el punto	20
6.4	Entrenamiento y validación	21
7	Módulo 3 — Plusvalía: qué zonas subirán y cuánto	22
7.1	El objeto de pronóstico	22
7.2	Las señales adelantadas	23
7.3	Modelado	23
7.4	Validación honesta	23
8	Módulo 5 — El motor de oportunidades	25
8.1	Las tres jugadas	25
8.1.1	Jugada A: subvaluación (comprar barato hoy)	25
8.1.2	Jugada B: plusvalía (comprar antes de que suba)	25
8.1.3	Jugada C: redensificación (comprar suelo disfrazado de casa)	25
8.2	Anatomía de una ficha de oportunidad	26

8.3 Del hallazgo al ranking	27
9 Módulo 4 — Capa urbana: uso de suelo y conectividad	28
9.1 Uso de suelo: qué se puede construir y dónde	28
9.1.1 El sistema de zonificación de la CDMX	28
9.1.2 Pipeline de datos normativos	29
9.2 Conectividad: el valor de estar cerca de donde pasa la vida	29
9.2.1 Polos de referencia	29
9.2.2 El índice de accesibilidad	29
9.2.3 Productos de esta capa	30
10 Módulo 6 — Optimizador: “Tengo 30 millones”	31
10.1 La experiencia objetivo	31
10.2 Formulación	31
10.3 Ejemplo de salida (ilustrativo)	32
11 La plataforma: producto y experiencia	33
11.1 Mapa del producto	33
11.2 Flujo insignia: Constructor de Portafolio	33
11.3 Sistema visual de la interfaz	33
11.4 Modelo de negocio (esbozo)	34
12 Roadmap: fases y puntos de control	35
12.1 Filosofía de ejecución	35
12.2 Las fases	35
12.3 Equipo mínimo	37
13 Riesgos, ética y marco legal	38
13.1 Matriz de riesgos	38
13.2 Compromisos éticos operativos	38

14 Anexos	40
14.1 Anexo A — Esquema de la tabla propiedad (v1)	40
14.2 Anexo B — Glosario	40
14.3 Anexo C — Preguntas que el sistema debe poder responder	41

1 Resumen ejecutivo

CIMENTA es una plataforma de inteligencia inmobiliaria cuantitativa para México. Su propósito se resume en una sola frase: **dado un capital disponible, decir con evidencia dónde invertirlo en bienes raíces, por qué, y cuánto se espera ganar.**

La promesa del producto

El usuario escribe: “*Tengo 30 millones de pesos*”. La plataforma responde con las **5 mejores oportunidades** del mercado en ese momento, diversificadas por zona y tipo de jugada, con tesis de inversión, montos, plazos y retorno esperado para cada una.

1.1 Qué construiremos

El sistema se compone de seis módulos encadenados, cada uno alimentando al siguiente:

1. **Ingesta (scraping).** Recolección diaria de anuncios de los 10 portales inmobiliarios más relevantes de México, normalizados en un esquema único con geolocalización.
2. **Valuación automática (AVM).** Un modelo que estima cuánto *debería* valer cada propiedad, independientemente del precio al que esté anunciada.
3. **Plusvalía predictiva.** Un modelo por colonia que pronostica si una zona subirá de precio, cuánto y con qué confianza, en horizontes de 1 a 5 años.
4. **Capa urbana.** Uso de suelo oficial (qué se puede construir y a cuántos niveles) y conectividad de cada propiedad con los polos de empleo y vida de la ciudad: Reforma, Polanco, Del Valle, Roma–Condesa, Santa Fe.
5. **Motor de oportunidades.** Cruce de los módulos anteriores para detectar tres tipos de jugada: comprar barato (subvaluación), comprar antes de que suba (plusvalía) y comprar para redensificar (arbitraje de uso de suelo).
6. **Optimizador de portafolio.** Dado un capital, selecciona la combinación de oportunidades que maximiza el retorno esperado sujeto a restricciones de diversificación y riesgo.

Analogía

CIMENTA es al mercado inmobiliario lo que un **sistema de apuestas de valor** es a las casas de apuestas deportivas. Una casa de apuestas publica un momio (su “precio” del partido); un apostador cuantitativo construye su propio modelo de probabilidad y apuesta solo cuando su estimación difiere lo suficiente del momio publicado. Aquí, el *momio* es el precio de lista del vendedor, nuestro *modelo de probabilidad* es el AVM, y la *apuesta de valor* es la propiedad cuyo precio de lista está claramente por debajo de su valor estimado. La disciplina es idéntica: nunca opinar, siempre medir el diferencial.

1.2 Por qué ahora

Tres condiciones coinciden por primera vez: (i) los portales concentran ya la gran mayoría de la oferta visible del país y son técnicamente accesibles; (ii) el gobierno de la CDMX publica datos abiertos de uso de suelo, catastro y movilidad con calidad suficiente para modelar; y (iii) el costo de las herramientas (cómputo, modelos de lenguaje para limpiar texto libre, motores de ruteo de código abierto) cayó a niveles operables por un equipo pequeño.

1.3 Cifras objetivo del plan

Indicador	Meta a 12 meses	Meta a 24 meses
Anuncios activos monitoreados	350,000	900,000
Cobertura geográfica	ZMVM completa	12 principales ciudades
Error mediano del AVM (MdAPE)	$\leq 12\%$	$\leq 8\%$
Precisión direccional plusvalía (1 año)	$\geq 65\%$	$\geq 72\%$
Oportunidades verificadas/mes	40	150

1.4 Estructura de este documento

Los capítulos 2 y 3 establecen la marca y el mercado. Los capítulos 4 a 10 son el corazón técnico: arquitectura, los seis módulos y sus modelos matemáticos. Los capítulos 11 y 12 aterrizan la plataforma y el plan de ejecución por fases con puntos de control verificables. Los capítulos finales cubren riesgos, aspectos legales y anexos de referencia.

2 Identidad: la marca CIMENTA

2.1 El nombre

CIMENTA proviene de *cimiento* y del verbo *cimentar*: poner la base sobre la que se construye todo lo demás. Es una palabra en español, pronunciable en inglés, de tres sílabas, con dominio corto disponible en variantes (`cimenta.mx`, `cimenta.ai`). Comunica exactamente lo que el producto hace: dar fundamento cuantitativo a decisiones que hoy se toman por intuición.

2.2 El logotipo



El isotipo son **tres bloques ascendentes** —los cimientos que crecen— atravesados por un **trazo de plusvalía** que termina en un punto: el dato. Tres lecturas conviven en la misma figura: un skyline en construcción, una gráfica de barras y la idea de progresión (gris → azul acento → azul profundo). El trazo superior es deliberadamente una línea de serie de tiempo, no una flecha de marketing: no prometemos que todo sube, prometemos que lo medimos.

2.3 Paleta de color

Color	Hex	Rol	Uso
Azul Cimiento	#16324F	Primario	Títulos, logo, fondos hero
Azul Acento	#2D7DD2	Interactivo	Botones, enlaces, métricas vivas
Azul Claro	#D8E6F3	Soporte	Fondos de tarjetas, mapas
Gris Grafito	#43484D	Texto	Cuerpo de texto, ejes
Gris Niebla	#AEB6BD	Detalle	Líneas, divisores, anotaciones
Fondo Claro	#F5F7F9	Lienzo	Fondo general de la interfaz

La regla de proporción es **70 / 25 / 5**: 70% lienzo claro y grises, 25% azul profundo estructural, 5%

azul acento reservado exclusivamente para *lo que el usuario debe ver primero* (una oportunidad, un botón de acción, una cifra de retorno). El verde sobrio (#2E8B6E) aparece solo en señales positivas verificadas, nunca como decoración.

2.4 Tipografía y tono

Tipografía sans-serif geométrica en toda la interfaz y documentos (en web: *Inter* para texto y *Space Grotesk* para cifras y titulares). El tono de comunicación es el de un **analista que respeta a su lector**: frases declarativas, cifras con intervalos, cero superlativos. CIMENTA nunca dice “¡increíble oportunidad!”; dice “precio 18% por debajo del valor estimado, intervalo [12%, 24%], 14 comparables”.

2.5 Principios de diseño de producto

- **Una pantalla, una decisión.** Cada vista responde una sola pregunta del usuario.
- **El mapa es la interfaz.** La unidad mental del inversionista inmobiliario es la colonia, no la tabla.
- **Evidencia a un clic.** Toda cifra es expandible hasta sus comparables y supuestos.
- **Silencio por defecto.** Si no hay oportunidad clara, la plataforma lo dice. La ausencia de recomendación también es información.

3 El mercado y el problema

3.1 El problema en una imagen

Una persona con 3 o 30 millones de pesos que quiere invertir en vivienda en México enfrenta hoy un mercado donde el precio de lista es una declaración unilateral del vendedor, los datos de transacciones reales son opacos, la plusvalía se discute con anécdotas (“Roma ya subió, ahora todos dicen que sigue Doctores”) y el potencial constructivo de un predio requiere descifrar normativa de uso de suelo que casi nadie consulta. El resultado: decisiones de millones de pesos tomadas con menos datos que una compra de pantalla en el Buen Fin.

Analogía

El mercado inmobiliario mexicano hoy es como un **mercado de valores sin ticker**: imagina invertir en acciones si cada empresa anunciara su precio en una lona, sin histórico, sin volumen, sin estados financieros comparables. CIMENTA construye el ticker: precio observado, valor estimado, tendencia de la “acción” (la colonia) y los fundamentales del “emisor” (uso de suelo, conectividad, oferta entrante).

3.2 Asimetrías que generan la oportunidad

1. **Asimetría de información de precio.** Sin un AVM público de referencia, los precios de lista exhiben dispersión enorme dentro de una misma colonia para productos comparables. Esa dispersión es la oportunidad: donde hay ruido, hay activos mal valuados.
2. **Asimetría temporal.** Las señales que anticipan plusvalía (permisos de construcción, apertura de comercios, mejoras de transporte, recomposición demográfica) son públicas meses o años antes de que el precio las refleje.
3. **Asimetría normativa.** Dos predios contiguos pueden tener el mismo precio por m² de terreno y potenciales constructivos radicalmente distintos (2 niveles vs. 6 niveles). El mercado de casas usadas rara vez valúa el derecho de construir; un comprador informado sí.

3.3 A quién servimos

Segmento	Necesidad	Capital típico
Inversionista patrimonial	“¿Dónde pongo mi dinero para que rinda más que un CETE sin perderlo?”	2–10 MDP
Inversionista activo / flipper	Encontrar propiedades subvaluadas antes que otros y dimensionar remodelación o redensificación	5–50 MDP
Desarrollador boutique	Predios con uso de suelo favorable en zonas con plusvalía entrante	20–200 MDP
Comprador de vivienda propia	“¿Mi colonia es buena inversión o solo me gusta?”	2–8 MDP

El producto inicial se enfoca en los dos primeros segmentos, que pagan por señal accionable, y trata al cuarto como canal de adquisición masiva (la versión gratuita responde “¿cuánto vale mi zona y hacia dónde va?”).

3.4 Ámbito geográfico inicial

Fase 1: **Zona Metropolitana del Valle de México**, con profundidad especial en las alcaldías Benito Juárez, Cuauhtémoc, Miguel Hidalgo, Coyoacán, Álvaro Obregón y Azcapotzalco, donde se concentran simultáneamente liquidez de mercado, datos públicos de calidad y dinámicas de redensificación. Fase 2: Guadalajara, Monterrey, Querétaro, Mérida, Puebla.

Punto de atención

Este plan usa cifras objetivo y ejemplos ilustrativos para dimensionar el sistema. Antes de comprometer capital real, cada cifra de mercado citada debe validarse contra los datos recolectados por el propio sistema en la Fase 0–1: la primera función del pipeline es sustituir supuestos por mediciones.


4 Arquitectura general del sistema

4.1 Vista de pájaro

El sistema es un **pipeline de refinación de datos**: entra texto sucio de anuncios y salen decisiones de inversión rankeadas. Cada módulo agrega una capa de significado al dato anterior.

Analogía

Piensa en una **refinería de petróleo**. El crudo (anuncios con texto libre, fotos, precios inflados, duplicados) entra por un extremo. Cada torre de destilación separa una fracción más valiosa: primero limpieza y deduplicación (quitar el agua y la arena), luego valuación (clasificar el octanaje), luego señales de zona (mezclar con aditivos de contexto urbano), y al final el optimizador empaqueta el producto terminado: un portafolio. Nadie compra crudo; nadie debería comprar “listados”. Se compra el destilado: la decisión.



4.2 Decisiones de arquitectura

Capa	Tecnología propuesta	Justificación
Scraping	Scrapy + Playwright (sitios con JS), proxies rotativos	Madurez, control fino de tasa de peticiones, comunidad
Orquestación	Airflow (o Prefect) con DAGs diarios	Reintentos, monitoreo, dependencia entre módulos
Almacenamiento	PostgreSQL + PostGIS; parquet en data lake para histórico	Lo geoespacial es ciudadano de primera clase; parquet para entrenamiento
Modelos	Python: LightGBM/XGBoost, statsmodels, scikit-learn	Estado del arte tabular; interpretabilidad vía SHAP
Ruteo	OSRM o Valhalla auto-hospedado sobre OpenStreetMap	Isócronas ilimitadas sin costo por petición
Backend	FastAPI + Pydantic	Tipado fuerte, documentación automática
Frontend	React + MapLibre GL	Mapas vectoriales de marca, sin dependencia de licencias
LLM auxiliar	Extracción de atributos desde texto libre de anuncios	“Acepta crédito”, “remato”, “uso de suelo H/3/20” viven en la descripción

4.3 El esquema de datos central

Todo converge en dos tablas maestras:

propiedad (grano: anuncio deduplicado): identificador canónico, geometría (punto), colonia, tipo, superficie de terreno y construcción, recámaras, baños, estacionamientos, antigüedad, precio de lista e histórico de cambios de precio, días en mercado, portal(es) de origen, atributos extraídos del texto libre, *valor estimado AVM* con intervalo, y banderas de calidad del dato.

colonia (grano: colonia–mes): índice de precio por m² (mediana ajustada por mezcla), volumen de oferta, días en mercado medianos, descuento lista–cierre estimado, señales adelantadas (permisos, comercios, transporte), pronóstico de plusvalía a 12/36/60 meses con intervalos, y métricas de conectividad agregadas.

Principio rector

El anuncio miente; el conjunto de anuncios no. Un precio individual puede estar inflado o ser un anzuelo, pero la distribución de cientos de precios comparables, observada en el tiempo, converge a la verdad del mercado. Toda la arquitectura está diseñada para razonar sobre distribuciones, nunca sobre datos puntuales.

5 Módulo 1 — Ingesta: los diez portales

5.1 El universo de fuentes

La oferta inmobiliaria visible de México se concentra en un puñado de portales. La selección prioriza volumen de anuncios, calidad estructurada del dato y complementariedad (cada portal aporta un segmento que los otros cubren mal).

#	Portal	Aporte distintivo	Dificultad técnica
1	Inmuebles24	Mayor volumen en CDMX/ZMVM; histórico de precios; profesionales	Alta
2	Propiedades.com	Buenos metadatos estructurados; analítica de zona propia	Media
3	Lamudi México	Segmento medio–alto; desarrollos nuevos (pre-venta)	Media
4	Vivanuncios	Cola larga de particulares; precios “de dueño”	Media
5	Mercado Libre Inmuebles	Enorme alcance de particulares; remates y prisa por vender	Alta
6	Casas y Terrenos	Fuerte en occidente; terrenos (clave para redensificación)	Baja
7	iCasas	Agregador con cobertura de provincia	Baja
8	Trovit / Mitula	Meta-buscador: detecta anuncios que solo viven en sitios chicos	Media
9	REMAX México	Inventario de brokers con datos disciplinados	Baja
10	Century 21 México	Ídem; buena cobertura de vivienda usada tradicional	Baja

A estas diez se suman dos fuentes “sombra” de alto valor estratégico: **portales de remates bancarios y de subasta judicial** (precios de liquidación que anclan el piso del mercado) y **grupos públicos de venta directa** (señal temprana de vendedores motivados). Se incorporan en Fase 2.

5.2 Arquitectura de recolección

5.2.1 Patrón general por portal

Cada portal se modela como un *spider* independiente con tres etapas: descubrimiento (recorrer listados por alcaldía/colonia y rango de precio para burlar topes de paginación), detalle (visitar cada anuncio nuevo o modificado) e ingesta (validar contra esquema y encolar). Los sitios con render de JavaScript pesado o protección anti-bot usan Playwright con navegador real; el resto, peticiones HTTP directas, siempre con límites de tasa conservadores (objetivo: ser indistinguibles de un usuario intensivo, jamás degradar el servicio del portal).

5.2.2 Deduplicación: el problema central

La misma casa aparece en 4 portales, publicada por 3 asesores, con fotos distintas y precios que difieren 5%. Sin resolverlo, todo lo demás se contamina (una casa contada cuatro veces distorsiona la oferta de su colonia).

La estrategia es un *matching* por capas, de barato a caro:

1. **Llave dura:** misma geolocalización (<30 m) + superficie construida ($\pm 5\%$) + recámaras.
2. **Similitud textual:** embeddings de la descripción; los asesores copian y pegan.
3. **Huella visual:** hash perceptual de fotos (pHash); la foto de la fachada delata al duplicado aunque cambie el texto.
4. **Resolución:** los candidatos que superan umbral se fusionan en un *anuncio canónico* que conserva el mejor dato de cada fuente y registra el precio mínimo observado.

Analogía

La deduplicación es el **control antidopaje** del pipeline: no es glamorosa, nadie la ve, pero sin ella toda la tabla de posiciones (los índices de precio por colonia) queda invalidada. Por eso tiene métricas propias y revisión humana muestral permanente.

5.2.3 Enriquecimiento con LLM

El 40–60% de la información útil de un anuncio vive en el texto libre: “uso de suelo H/3/20”, “se aceptan créditos”, “para remodelar”, “remato por viaje”, “ideal para constructores”. Un extractor con modelo de lenguaje convierte cada descripción en atributos estructurados con un esquema cerrado de ~ 25 campos, incluyendo las dos señales de oro: **motivación del vendedor** y **potencial constructivo declarado**.

5.2.4 Geocodificación y asignación de colonia

Los anuncios rara vez traen dirección exacta. El proceso encadena: coordenadas del mapa del portal (cuando existen) → geocodificación de la dirección parcial → asignación por polígono oficial de colonia (catálogo de colonias CDMX / marco geoestadístico INEGI). Toda propiedad termina con un punto, una colonia y una alcaldía; las que no alcanzan confianza mínima se etiquetan y se excluyen de los índices.

5.3 Frecuencia, volumen y monitoreo

- **Frecuencia:** descubrimiento diario; re-visita de anuncios activos cada 3 días (para capturar *cambios de precio*, la señal conductual más valiosa: un recorte de precio es un vendedor que aprende).
- **Ciclo de vida:** un anuncio que desaparece se marca como *retirado*; el tiempo en mercado y el último precio observado alimentan el modelo de descuento lista–cierre.
- **Monitoreo:** tablero con anuncios nuevos/retirados por portal y día, tasa de error de parseo y *drift* de esquema (los portales rediseñan sin avisar; cada spider tiene pruebas de contrato que truenan ruidosamente al primer cambio).

Punto de atención

Marco legal y de cortesía técnica. La recolección se limita a información pública, sin evadir autenticación, respetando `robots.txt` cuando aplica, con tasas de petición que no afecten el servicio, y sin almacenar datos personales de los anunciantes más allá de lo indispensable (se descartan teléfonos y nombres). Los términos de uso de cada portal se revisan con abogado antes de activar su spider, y el plan de negocio no depende de ningún portal individual: la redundancia de diez fuentes es también una estrategia de resiliencia legal.

6 Módulo 2 — AVM: cuánto debería valer cada propiedad

6.1 Definición del problema

Un *Automated Valuation Model* estima el valor de mercado $\hat{V}$ de una propiedad a partir de sus características y su contexto, independientemente del precio al que el vendedor la haya anunciado. Es la pieza que convierte a CIMENTA de un buscador en un juez.

Analogía

El AVM es la **Guía Autométrica de las casas** (el “libro azul” que los compradores de autos usados consultan antes de negociar). Hoy, quien compra un auto de 300 mil pesos tiene una referencia objetiva de valor; quien compra una casa de 8 millones, no. El AVM es ese libro azul, recalculado todas las noches, para cada vivienda anunciada en el país.

6.2 La variable objetivo y su trampa

Solo observamos **precios de lista**, no precios de cierre. Modelar lista a secas heredaría el optimismo de los vendedores. La corrección tiene tres fuentes:

1. **Trayectoria del anuncio:** el último precio antes del retiro es un techo mucho más honesto que el precio inicial; los recortes sucesivos revelan la curva de aprendizaje del vendedor.
2. **Función de descuento** $\delta(\text{zona}, \text{segmento}, t)$: estimada con las pocas fuentes de cierre disponibles (avalúos de referencia, índice SHF, transacciones reportadas) y calibrada por días en mercado.
3. **Definición operativa:** $V \approx P_{\text{última lista}} \cdot (1 - \delta)$, con δ típicamente entre 4% y 12% según zona y liquidez.

6.3 Arquitectura del modelo

6.3.1 Modelo hedónico base (interpretable)

Primero, una regresión hedónica log-lineal que descompone el precio en el valor implícito de cada atributo:

$$\log V_i = \alpha + \sum_k \beta_k x_{ik} + \gamma_{c(i)} + \varepsilon_i$$

donde x_{ik} son atributos (m² construidos, m² de terreno, recámaras, baños, edad, estacionamientos) y $\gamma_{c(i)}$ un efecto fijo por colonia. Este modelo no gana en precisión, pero produce los *precios sombra* que el negocio necesita comunicar: “en Del Valle, un cajón de estacionamiento adicional vale $\sim X$; un nivel extra de construcción permitido vale $\sim Y$ por m² de terreno”.

6.3.2 Modelo de producción (gradient boosting espacial)

El estimador de producción es un ensamble de gradient boosting (LightGBM) sobre ~ 80 – 150 *features* en cuatro familias:

- **Físicas:** superficies, programa arquitectónico, edad, estado declarado (extraído por LLM), tipo (casa, departamento, terreno).
- **De ubicación fina:** estadísticos de los k vecinos comparables más cercanos (mediana de precio/m² a 300/800/1500 m), distancia a vialidades primarias, parques, metro.
- **De zona:** índice de precio de la colonia, su tendencia, días en mercado, mezcla de producto, nivel socioeconómico (INEGI).
- **Normativas y de conectividad:** uso de suelo y niveles permitidos (cap. 9), índice de accesibilidad a polos de empleo (cap. 9).

La componente espacial residual (lo que la colonia no captura: la calle bonita, el frente al parque) se modela con un suavizado tipo *kriging* sobre los residuos, sumado al predictor base.

6.3.3 Incertidumbre: el intervalo importa más que el punto

Cada valuación se entrega como tercia ($\hat{V}_{10}, \hat{V}_{50}, \hat{V}_{90}$) mediante regresión por cuantiles. Un intervalo angosto significa colonia líquida y producto estándar; uno ancho, mercado delgado. **El motor de oportunidades exige que el precio de lista esté por debajo de $\hat{V}_{10}$** , no de la mediana: solo así un “descuento” es estadísticamente exigible y no ruido del modelo.

6.4 Entrenamiento y validación

- **Partición temporal estricta:** entrenar con anuncios hasta t , validar con anuncios posteriores. Jamás validación aleatoria (filtraría el futuro al pasado, el pecado capital de los modelos de precios).
- **Partición espacial complementaria:** validar dejando colonias enteras fuera, para medir cuánto generaliza a zonas con pocos datos.
- **Métricas:** MdAPE (error porcentual absoluto mediano; meta $\leq 12\%$ en Fase 1, $\leq 8\%$ en madurez), PPE10 (proporción de predicciones con error $\leq 10\%$; meta $\geq 55\%$), y cobertura de intervalos (el 80% nominal debe contener $\sim 80\%$ real).
- **Auditoría de sesgo:** error desagregado por alcaldía, segmento de precio y tipo; un AVM que valúa bien Polanco y mal Iztapalapa es un AVM que solo sirve para la mitad del mapa.

Punto de control del módulo (CP–AVM)

El AVM se declara apto para producción cuando, en validación temporal pura sobre tres meses no vistos: $\text{MdAPE} \leq 12\%$, $\text{PPE10} \geq 55\%$, cobertura de intervalo dentro de ± 5 puntos del nominal, y ninguna alcaldía del ámbito Fase 1 con $\text{MdAPE} > 18\%$. Hasta entonces, ninguna “oportunidad” sale al usuario.

7 Módulo 3 — Plusvalía: qué zonas subirán y cuánto

7.1 El objeto de pronóstico

La unidad de análisis es la **colonia–mes**. Para cada colonia c construimos primero su *índice de precio* $I_c(t)$: la mediana del precio por m² ajustada por mezcla de producto (si un mes se anuncian puros penthouses, la mediana cruda sube sin que la zona valga más; el ajuste hedónico lo corrige). El objetivo del módulo es pronosticar el crecimiento real del índice:

$$g_c(h) = \frac{I_c(t+h)}{I_c(t)} - 1 \quad \text{para } h \in \{12, 36, 60\} \text{ meses,}$$

entregado siempre como distribución (mediana e intervalo), deflactado por inflación, y acompañado de una **probabilidad direccional**: $\Pr[g_c(12) > \text{inflación} + 2\%]$.

Analogía

Una colonia es como un **equipo de fútbol a mitad de temporada**. Su precio actual es su posición en la tabla; pero para apostar por ella importan los *indicadores adelantados*: cómo está su cantera (permisos de construcción), sus fichajes (cafeterías y comercios nuevos), su calendario (líneas de transporte por inaugurar) y su racha (aceleración reciente del índice). El error clásico del aficionado —y del inversionista— es comprar al equipo que ya ganó la liga: Roma y Condesa ya cobraron su plusvalía; el modelo busca al equipo revelación dos jornadas antes de que el estadio se llene.

7.2 Las señales adelantadas

Familia	Señal concreta	Fuente
Construcción	Manifestaciones y permisos de obra; m ² autorizados por colonia	Datos abiertos CDMX
Comercio	Altas de unidades económicas: cafeterías, gimnasios, coworkings	DENUE (INEGI)
Transporte	Obras y líneas anunciadas (Metro, Metrobús, Cablebús, trenes)	Gacetas y proyectos públicos
Mercado	Aceleración del índice, compresión de días en mercado, caída de descuentos	Pipeline propio (M1)
Demografía	Recomposición de edad e ingreso, densificación	Censo y ENIGH (INEGI)
Contagio	Plusvalía realizada en colonias contiguas (efecto frontera)	Pipeline propio
Normativa	Cambios de programa de desarrollo urbano; corredores de redensificación	SEDUVI / gacetas

La señal de **contagio espacial** merece subrayarse: la plusvalía en CDMX se difunde por frontera, como mancha de aceite (Condesa → Escandón → San Pedro de los Pinos; Roma → Doctores → Obrera). Se modela explícitamente con rezagos espaciales: el crecimiento de las colonias vecinas en los últimos 24 meses es un *feature* del pronóstico de la colonia central.

7.3 Modelado

Estrategia de dos niveles:

1. **Panel econométrico base.** Regresión de panel con efectos fijos por colonia y rezagos espaciales (tipo Durbin espacial), sobre g_c a 12 meses. Aporta interpretabilidad y los elasticidades que el negocio comunica (“cada 10,000 m² de obra autorizada se asocian históricamente con $+x$ puntos de crecimiento a 3 años”).
2. **Gradient boosting de panel.** Mismo dataset, target a 12/36/60 meses, validación temporal con ventanas rodantes (entrenar 2017–2022, validar 2023; entrenar 2017–2023, validar 2024; etc.). Captura no linealidades, en particular el patrón de *saturación*: las señales adelantadas predicen mucho en colonias baratas respecto a sus vecinas y casi nada en colonias ya caras.

7.4 Validación honesta

- **Direccional:** ¿el modelo distingue colonias que superarán a la inflación de las que no? Meta: precisión $\geq 65\%$ a 12 meses (azar $\approx 50\%$).

- **Ranking:** correlación de Spearman entre crecimiento pronosticado y realizado por cohorte anual; lo que el optimizador usa es el *orden*, no el valor exacto.
- **Calibración probabilística:** Brier score de la probabilidad direccional, comparado contra el clima base (“todas las colonias crecen lo del promedio de la ciudad”). Si el modelo no le gana al clima base, no existe.
- **Backtest de papel:** cada trimestre se “compran” en papel las 10 colonias top del modelo y se mide su desempeño a 12–36 meses contra el promedio de la ciudad. Es el equivalente inmobiliario de una temporada de apuestas en seco antes de arriesgar bankroll.

Producto visible de este módulo

El **Mapa de Calor de Plusvalía**: cada colonia coloreada por su crecimiento esperado a 3 años, con tres capas conmutables (pronóstico, confianza, y “por qué”: la señal dominante). Es la pantalla con la que un usuario responde en diez segundos la pregunta “¿y mi colonia es buena inversión?” — y la principal pieza de adquisición viral de la plataforma.

8 Módulo 5 — El motor de oportunidades

8.1 Las tres jugadas

Una “oportunidad” en CIMENTA no es una corazonada: es la intersección verificable de un precio, un valor y una tesis. El motor reconoce tres arquetipos, cada uno con su propia matemática:

8.1.1 Jugada A: subvaluación (comprar barato hoy)

$$S_i = \frac{\hat{V}_{10,i} - P_i}{\hat{V}_{10,i}}$$

donde P_i es el precio de lista y $\hat{V}_{10,i}$ el percentil 10 del AVM. Exigir el percentil 10 (no la mediana) convierte el descuento en una afirmación conservadora: *incluso en el escenario pesimista del modelo, esta propiedad está barata*. Filtros adicionales: mínimo de comparables, sin banderas de calidad del dato, y verificación de que la “baratura” no se explique por un defecto observable (zona de riesgo, litigio mencionado en el texto, planta baja sin luz).

8.1.2 Jugada B: plusvalía (comprar antes de que suba)

Propiedades correctamente valuadas hoy ($S_i \approx 0$) pero en colonias del decil superior de crecimiento pronosticado con alta confianza. El retorno no viene del descuento sino del viento de cola de la zona. Métrica: $g_c(36)$ pronosticado $\times$ probabilidad direccional.

8.1.3 Jugada C: redensificación (comprar suelo disfrazado de casa)

La jugada del ejemplo fundacional del producto. Una casa vieja sobre un terreno cuyo uso de suelo permite construir varios niveles vale, para un desarrollador, su *valor residual*:

$$R_i = \underbrace{m_{\text{vendibles}}^2 \times p_{\text{venta}}}_{\text{ingreso del proyecto}} - \underbrace{m_{\text{construidos}}^2 \times c_{\text{obra}}}_{\text{costo duro}} - \text{indirectos} - \text{utilidad mínima exigida}$$

Si $R_i > P_i$ (el residual supera el precio de lista de la casa), existe arbitraje normativo: el mercado está vendiendo derechos de construcción a precio de casa usada. Aquí se conectan el módulo de uso de suelo (¿cuántos m² vendibles permite el predio?) y el AVM (¿a cuánto se venden los departamentos nuevos en esa colonia?).

Analogía

La jugada C es comprar una **carta coleccionable dentro de un álbum usado**: el vendedor pone precio al álbum (la casa vieja, que es lo que él ve); el comprador informado paga por la carta rara que viene adentro (el derecho de construir 1,000 m² vendibles). El módulo de uso de suelo es el catálogo que te dice qué álbumes traen carta rara.

8.2 Anatomía de una ficha de oportunidad

Toda oportunidad publicada en la plataforma sigue una plantilla rígida. Ejemplo ilustrativo del formato (cifras hipotéticas de diseño, no una recomendación real):

OPORTUNIDAD CIM-0847 · Jugada C (redensificación) · Col. Nativitas, Benito Juárez

El activo. Casa de 1965, 240 m² de terreno, 180 m² construidos, sobre calle secundaria a 400 m del Metro Nativitas. Precio de lista: **3.0 MDP** (12,500 \$/m² de terreno). AVM de la casa *como casa*: 3.2 MDP [2.9 – 3.6].

La tesis. El predio tiene zonificación habitacional de 3 niveles. Caben ~3 departamentos de 75 m² vendibles netos. Los departamentos nuevos comparables en Nativitas se venden hoy en ~26,500 \$/m² ($\approx$ 2.0 MDP por unidad), con absorción sana.

Los números (escenario central).

Compra del inmueble	3.00 MDP
Demolición + construcción (~310 m ² totales)	2.60 MDP
Indirectos, licencias, financieros, comercialización	0.85 MDP
Inversión total	6.45 MDP
Ingreso por venta (3 × 2.0 MDP)	6.00 MDP
Plusvalía pronosticada de la zona a 24 meses (+12%)	+0.72 MDP

Resultado a 24 meses **+0.27 MDP base / +1.1 MDP optimista**

Veredicto del motor. En escenario central, el margen es delgado: la oportunidad *solo* es atractiva si (a) se negocia la compra a ≤ 2.7 MDP (el vendedor lleva 140 días en mercado y dos recortes de precio: probabilidad alta), o (b) se confirma factibilidad de un 4º nivel vía corredor de redensificación. **Esto es exactamente lo que la plataforma debe mostrar: no la fantasía de “3 MDP de ganancia garantizada”, sino el árbol de decisión con sus condiciones.**

Contexto de zona. Nativitas está en el percentil 88 de plusvalía pronosticada de la CDMX: contagio desde Portales y Del Valle, +34% de m² de obra autorizada interanual, conectividad 82/100 (Metro L2, 18 min a Del Valle, 29 min a Reforma).

Por qué la honestidad es el producto

Cualquier portal puede prometer “gana 3 MDP en 2 años”. El activo defendible de CIMENTA es lo contrario: que cuando los números dan 0.27 y no 3.0, la ficha lo diga, y diga bajo qué condiciones la jugada sí funciona. Un usuario que pierde dinero por una ficha optimista no regresa; un usuario al que la plataforma le evitó una mala compra se queda años.

8.3 Del hallazgo al ranking

Cada oportunidad recibe una calificación compuesta:

$$\text{Score}_i = w_1 \underbrace{\text{retorno esperado anualizado}}_{\text{cuánto}} \times w_2 \underbrace{\text{confianza}}_{\text{qué tan seguro}} \times w_3 \underbrace{\text{liquidez de salida}}_{\text{qué tan fácil vender}}$$

con penalizaciones por datos incompletos y por concentración (muchas oportunidades simultáneas en la misma microzona suelen indicar un defecto común, no un milagro común). El resultado es la materia prima del optimizador de portafolio (cap. 10).

9 Módulo 4 — Capa urbana: uso de suelo y conectividad

9.1 Uso de suelo: qué se puede construir y dónde

9.1.1 El sistema de zonificación de la CDMX

En la Ciudad de México, cada predio tiene una zonificación definida por los Programas de Desarrollo Urbano (administrados por SEDUVI), expresada con una nomenclatura del tipo **H/3/20**:

- **Primera posición — uso:** H (habitacional), HC (habitacional con comercio en planta baja), HM (habitacional mixto), HO (habitacional con oficinas), E (equipamiento), I (industria), AV (áreas verdes), entre otros.
- **Segunda — niveles:** número máximo de pisos permitidos (2, 3, 4, 6...).
- **Tercera — área libre:** porcentaje mínimo del terreno que debe quedar sin construir (20%, 30%...).

De ahí se derivan los dos números que gobiernan el valor del suelo: el **COS** (coeficiente de ocupación: cuánta huella puedes cubrir) y el **CUS** (coeficiente de utilización: cuántos m² totales puedes construir = huella × niveles). A esto se suman las *Normas Generales de Ordenación* (la norma de densidad que limita número de viviendas por predio, corredores con derechos adicionales, áreas de conservación patrimonial que restringen, etc.).

Analogía

La zonificación es el **plan de datos del predio**: dos teléfonos idénticos valen distinto si uno tiene plan ilimitado y el otro 2 GB. Dos terrenos contiguos de 240 m² pueden costar lo mismo por m², pero el H/6/20 trae “plan ilimitado” (hasta ~1,150 m² construibles) y el H/2/50 trae “plan básico” (~240 m²). El mercado de casas usadas casi siempre cobra el teléfono e ignora el plan; CIMENTA lee la letra chica de cada contrato.

9.1.2 Pipeline de datos normativos

1. Ingesta de la capa pública de zonificación (portal de datos abiertos CDMX / SEDUVI) como polígonos con su clave.
2. Cruce espacial: cada propiedad del inventario hereda la zonificación de su predio.
3. Cálculo del **potencial constructivo**: m² máximos teóricos, número estimado de unidades, y la razón $\rho = \text{m}^2 \text{ construibles} / \text{m}^2 \text{ contruidos actuales}$. Un $\rho \geq 3$ con uso H o HC es el detonador de la jugada C.
4. Doble verificación documental: toda oportunidad de redensificación publicada exige, antes de su nivel máximo de confianza, el *Certificado Único de Zonificación* del predio específico — la capa pública orienta, el certificado manda.

Punto de atención

La normativa urbana cambia, tiene excepciones por predio (patrimonio, riesgo, restricciones de barranca o sismicidad) y los programas delegacionales tienen vigencias distintas. El sistema etiqueta cada dato normativo con su fuente y fecha, y la ficha de oportunidad declara explícitamente el nivel de verificación: *capa pública* → *certificado* → *factibilidad validada por perito*.

9.2 Conectividad: el valor de estar cerca de donde pasa la vida

9.2.1 Polos de referencia

La ciudad tiene un conjunto reconocible de polos de empleo, consumo y prestigio: **Reforma, Polanco, Roma–Condesa, Del Valle, Santa Fe, Centro, Insurgentes Sur, Coyoacán centro, Interlomas–Lomas**. La conectividad de una propiedad se mide contra todos ellos, ponderados por su masa de empleo.

9.2.2 El índice de accesibilidad

Con un motor de ruteo auto-hospedado (OSRM/Valhalla sobre OpenStreetMap, más los grafos de Metro, Metrobús, Cablebús y trenes) se calcula para cada propiedad el tiempo puerta a puerta t_{ij} a cada polo j , en auto en hora pico y en transporte público. El índice agrega con un *modelo gravitacional*:

$$A_i = \sum_j \frac{E_j}{(t_{ij})^\beta}$$

donde E_j es la masa de empleo del polo (DENUE) y $\beta \approx 1.5$ el decaimiento calibrado contra precios observados. Se normaliza a escala 0–100 por ciudad.

Analogía

El índice gravitacional funciona como la **señal de Wi-Fi**: cada polo es un router con potencia proporcional a su empleo, y las paredes son los minutos de tráfico. Una casa puede estar geométricamente cerca de Reforma y tener “dos rayitas” porque cruzar la ciudad a esa hora son 50 minutos; otra más lejana junto a una estación de Metro recibe “señal completa”. Lo que el mercado paga no son kilómetros: son minutos.

9.2.3 Productos de esta capa

- **Isócronas en la ficha:** “desde esta casa: Del Valle 18 min, Reforma 29 min, Polanco 41 min (transporte público, hora pico)”.
- **Feature del AVM:** la accesibilidad es de los predictores de precio más potentes; además permite detectar *conectividad nopreciada*: colonias con A_i alto y precio bajo, candidatas naturales a plusvalía.
- **Escenarios de infraestructura:** recalcular A_i con líneas de transporte anunciadas pero no inauguradas responde la pregunta de oro: *¿qué colonias se “acercan” a la ciudad cuando abra tal línea?* Históricamente, ahí está la plusvalía de dos dígitos.

10 Módulo 6 — Optimizador: “Tengo 30 millones”

10.1 La experiencia objetivo

El usuario introduce tres datos: **capital disponible**, **horizonte** (2, 5, 10 años) y **perfil** (conservador / balanceado / agresivo; y si participará activamente, p. ej. desarrollando, o solo comprará y esperará). La plataforma devuelve un **portafolio de 3 a 6 oportunidades concretas** con asignación de capital, tesis individual, retorno esperado agregado con intervalo, y plan de salida.

10.2 Formulación

Con el catálogo de oportunidades vigentes $\mathcal{O}$ (cap. 8), cada una con costo total k_i , retorno esperado anualizado μ_i , dispersión σ_i y atributos (colonia, alcaldía, tipo de jugada, liquidez), el problema base es una **selección de cartera con activos indivisibles** — más cercano a una mochila (knapsack) que a Markowitz clásico, porque las casas no se compran en fracciones:

$$\max_{x \in \{0,1\}^{|\mathcal{O}|}} \sum_i \mu_i k_i x_i - \lambda \text{Riesgo}(x)$$

sujeto a:

- $\sum_i k_i x_i \leq K$ (presupuesto, con colchón de liquidez del 8–10% para imprevistos de obra y escrituración),
- máximo 40% del capital en una misma alcaldía y 50% en un mismo tipo de jugada (diversificación dura),
- al menos una posición de alta liquidez si el perfil lo exige,
- compatibilidad con el perfil: la jugada C (desarrollo) solo entra si el usuario declaró participación activa.

El término de riesgo usa la matriz de correlación entre colonias estimada del histórico de índices: dos casas en colonias contiguas comparten destino; el optimizador lo sabe y lo castiga. La resolución es programación entera (el catálogo vigente tiene cientos de oportunidades, no millones:

se resuelve exacto en segundos) y se entregan, además del óptimo, dos portafolios alternativos de la frontera (más conservador / más agresivo).

Analogía

El optimizador aplica la lógica del **gestor de bankroll de un apostador profesional**: nunca toda la cartera a una sola apuesta por buena que parezca (riesgo de ruina), nunca cinco apuestas al mismo partido disfrazadas de diversificación (cinco casas en la misma colonia), y el tamaño de cada posición crece con la *ventaja* estimada y decrece con su *incertidumbre* — el espíritu del criterio de Kelly fraccional, adaptado a activos indivisibles e ilíquidos.

10.3 Ejemplo de salida (ilustrativo)

Entrada: “Tengo 30 MDP, horizonte 3 años, perfil balanceado, dispuesto a desarrollar un proyecto.”

#	Oportunidad	Capital	Ret. esp.	Jugada
1	Redensificación, Col. Nativitas (BJ): casa → 3 deptos	6.5 MDP	14–22%/a	C
2	Depto subvaluado –16% vs AVM, Col. Narvarte Pte.	4.2 MDP	9–13%/a	A
3	Casa en corredor de contagio, Col. San Pedro de los Pinos	5.8 MDP	8–14%/a	B
4	Terreno HC/4 junto a obra de transporte, Azcapotzalco	7.1 MDP	11–19%/a	B+C
5	Depto líquido y estable, Col. Del Valle Sur (ancla del portafolio)	3.9 MDP	5–8%/a	A
	Colchón de liquidez	2.5 MDP	—	—
	Total	30.0 MDP	9.5–15%/a	

Cada renglón es expandible a su ficha completa (cap. 8), y el agregado muestra la distribución simulada del valor del portafolio a 3 años (Monte Carlo sobre los intervalos de cada posición y las correlaciones entre colonias), con su probabilidad de pérdida nominal — el número que un asesor tradicional jamás te da.

Punto de atención

La plataforma **informa, no asesora**: presenta análisis cuantitativo con supuestos explícitos para que el usuario decida e investigue (due diligence legal, inspección física, asesoría fiscal son insustituibles). Este deslinde no es letra chica defensiva: es coherente con el valor de humildad estadística de la marca y se muestra en la interfaz, no escondido en términos y condiciones.

11 La plataforma: producto y experiencia

11.1 Mapa del producto

Cinco superficies, una por pregunta del usuario:

Superficie	Pregunta que responde	Acceso
Mapa de Plusvalía	“¿Hacia dónde va mi colonia / la ciudad?”	Gratuito
Valuador	“¿Cuánto vale esta propiedad realmente?”	Gratuito limitado
Radar de Oportunidades	“¿Qué está barato hoy y por qué?”	Suscripción
Constructor de Portafolio	“Tengo \$X: ¿cómo lo invierto?”	Suscripción Pro
Sala de Análisis	Ficha profunda: comparables, isócronas, residual, escapes	Suscripción Pro

La capa gratuita (mapa y valuador) es el embudo: responde la pregunta universal —“¿y mi casa?, ¿y mi zona?”— y convierte curiosidad en registro. Las capas de pago venden lo accionable.

11.2 Flujo insignia: Constructor de Portafolio

1. **Entrada** (una pantalla): capital, horizonte, perfil, participación activa sí/no.
2. **Resultado** (una pantalla): las 5 posiciones sobre el mapa de la ciudad, lista lateral con capital y retorno por posición, banda de resultado agregado a horizonte.
3. **Profundidad** (bajo demanda): clic en cualquier posición → ficha completa con evidencia; clic en la banda agregada → distribución simulada y supuestos.
4. **Acción**: exportar el portafolio como dossier PDF con la plantilla de marca, y activar alertas (“avísame si aparece algo mejor o si una posición cambia de precio”).

11.3 Sistema visual de la interfaz

Fondo claro #F5F7F9, cartografía en grises con agua y parques apenas insinuados, y **el azul acento reservado a las oportunidades**: en un mapa casi monocromo, el ojo encuentra la señal

sin leyenda. Tipografía Inter; cifras grandes en Space Grotesk tabular. Sin gradientes decorativos, sin sombras profundas: el dato es el ornamento.

11.4 Modelo de negocio (esbozo)

- **Suscripción individual** (Radar + Portafolio): plan mensual/anual, precio ancla por debajo del costo de *una* mala visita con asesor.
- **Pro / equipos** (brokers, family offices, desarrolladores boutique): asientos múltiples, exportes, API.
- **Dossiers a demanda**: análisis profundo de un predio específico (incluye verificación documental de zonificación) como compra única — puerta de entrada sin suscripción.
- **Lo que no haremos**: vender los leads de los usuarios a inmobiliarias. El usuario es el cliente, no el producto; la confianza es el foso competitivo de una marca cuyo producto es el juicio.

12 Roadmap: fases y puntos de control

12.1 Filosofía de ejecución

El plan avanza por **puntos de control (CP) verificables**: cada fase tiene una condición de salida medible y nada de la fase siguiente se construye hasta cruzarla. El orden está diseñado para que el riesgo más letal de cada etapa se enfrente primero (¿hay dato suficiente? → ¿el AVM es bueno? → ¿las oportunidades son reales? → ¿alguien paga?).

12.2 Las fases

Fase 0 — Sonda (semanas 1–6)

Spiders mínimos de los 3 portales mayores, solo Benito Juárez y Cuauhtémoc; esquema de datos v1; deduplicación básica.

CP0 — ¿Existe la materia prima?

$\geq 25,000$ anuncios únicos recolectados; tasa de duplicados residual $\leq 5\%$ en muestra auditada a mano; $\geq 90\%$ de anuncios con colonia asignada con confianza alta. *Si CP0 falla, el proyecto se redefine antes de gastar un peso en modelos.*

Fase 1 — Juez (meses 2–5)

Los 10 portales activos en ZMVM; enriquecimiento LLM; AVM v1 con intervalos; índices de colonia.

CP1 — ¿El juez es justo?

Criterios del CP–AVM (cap. 6): $\text{MdAPE} \leq 12\%$, $\text{PPE}_{10} \geq 55\%$, cobertura de intervalos correcta, sin alcaldía descolgada.

Fase 2 — Oráculo (meses 4–8, traslapada)

Histórico de señales adelantadas; modelo de plusvalía; capa de uso de suelo y conectividad; mapa de calor público en beta.

CP2 — ¿El oráculo le gana al azar?

Precisión direccional $\geq 65\%$ y Spearman ≥ 0.45 en backtest de ventanas rodantes; Brier del modelo $<$ Brier del clima base en todas las cohortes.

Fase 3 — Cazador (meses 7–11)

Motor de oportunidades con las tres jugadas; verificación documental muestral de zonificación; 90 días de *paper trading*: cada oportunidad publicada internamente se sigue hasta su desenlace (¿se vendió?, ¿a cuánto?, ¿el descuento era real?).

CP3 — ¿Las oportunidades sobreviven al contacto con la realidad?

En el seguimiento a 90 días: $\geq 70\%$ de las oportunidades tipo A se venden a precio $\geq 95\%$ del AVM (el descuento era real); $\leq 10\%$ resultan tener defecto descalificante no detectado. Auditoría externa de 20 fichas por un valuador profesional.

Fase 4 — Plataforma (meses 10–14)

Optimizador de portafolio; producto web completo con las cinco superficies; beta cerrada con 50 usuarios de los segmentos objetivo; dossiers PDF automatizados.

CP4 — ¿Alguien paga por el juicio?

$\geq 25\%$ de la beta convierte a plan de pago al abrir cobro; NPS ≥ 40 ; al menos 3 operaciones de compra reales reportadas por usuarios citando la plataforma como factor de decisión.

Fase 5 — Expansión (meses 14+)

Guadalajara, Monterrey, Querétaro, Mérida, Puebla; fuentes sombra (remates); API para equipos; escenarios de infraestructura.

12.3 Equipo mínimo

Núcleo de 4: ingeniero de datos (pipeline y spiders), científico de datos (AVM y plusvalía), desarrollador full-stack (plataforma) y un perfil híbrido producto/inmobiliario (verificación, fichas, relación con valuadores y notarios). Asesores externos: legal (datos y términos de uso) y un valuador certificado para las auditorías de CP.

13 Riesgos, ética y marco legal

13.1 Matriz de riesgos

Riesgo	Descripción	Mitigación
Bloqueo de portales	Cambios anti-bot o legales cortan una fuente	Redundancia de 10 fuentes; ningún portal > 30% del dato; tasas cortes; revisión legal previa por portal
Sesgo de precios de lista	El AVM hereda optimismo de vendedores	Función de descuento calibrada; uso del último precio; validación contra avalúos
Cisne de mercado	Recesión, sismo, cambio fiscal mueven todo el mercado	Los pronósticos son relativos a la ciudad (ranking), no absolutos; escenarios de estrés en el optimizador
Cambio normativo	Programas de desarrollo urbano se modifican	Versionado de la capa normativa; jugada C exige certificado del predio
Riesgo reputacional	Una ficha errónea con pérdida visible	CPs de calidad; auditoría externa; lenguaje de intervalos; seguimiento público de desempeño de fichas
Datos personales	Anuncios contienen teléfonos y nombres	Descartar PII en ingesta; cumplimiento LFPDPPP; aviso de privacidad
Dependencia de talento	Equipo pequeño, conocimiento concentrado	Documentación como ciudadano de primera clase desde Fase 0

13.2 Compromisos éticos operativos

1. **Solo información pública.** Sin evasión de autenticación ni recolección de datos personales; agregación y anonimización por defecto.
2. **El desempeño se publica.** Un tablero público mostrará el error histórico del AVM y el acierto de los pronósticos de plusvalía por cohorte. Quien vende juicio debe dejarse calificar.
3. **Sin conflicto de interés.** CIMENTA no compra propiedades que sus modelos señalan ni cobra comisión de venta a inmobiliarias por aparecer mejor. La señal no está en venta.
4. **Conciencia del entorno.** Las herramientas de detección de plusvalía participan de dinámicas de gentrificación. El compromiso mínimo: la capa gratuita da a los *residentes* de una

colonia la misma información que a los inversionistas; la asimetría de información no debe correr en una sola dirección.

14 Anexos

14.1 Anexo A — Esquema de la tabla `propiedad` (v1)

Campo	Tipo	Notas
<code>id_canonico</code>	<code>uuid</code>	Tras deduplicación
<code>fuentes</code>	<code>jsonb</code>	Portales, urls, ids de origen
<code>geom</code>	<code>point (4326)</code>	Confianza de geocodificación adjunta
<code>colonia_id / alcaldia</code>	<code>fk</code>	Polígonos oficiales
<code>tipo</code>	<code>enum</code>	casa, depto, terreno, mixto
<code>m2_terreno / m2_construccion</code>	<code>numeric</code>	Validación cruzada de coherencia
<code>recamaras / banos / estacionamientos</code>	<code>int</code>	—
<code>antiguedad</code>	<code>int</code>	Años; extraída o declarada
<code>precio_lista / historial_precios</code>	<code>numeric / jsonb</code>	Cambios con fecha
<code>dias_en_mercado</code>	<code>int</code>	Desde primera observación
<code>atributos_llm</code>	<code>jsonb</code>	25 campos: motivación, estado, uso de suelo declarado...
<code>zonificacion</code>	<code>jsonb</code>	Clave, niveles, área libre, fuente, fecha, nivel de verificación
<code>avm_p10 / avm_p50 / avm_p90</code>	<code>numeric</code>	Con versión de modelo
<code>accesibilidad</code>	<code>numeric</code>	Índice 0–100 + tiempos a polos
<code>flags_calidad</code>	<code>jsonb</code>	Geocodificación dudosa, outlier, etc.

14.2 Anexo B — Glosario

AVM

Modelo de valuación automática: estima el valor de mercado de una propiedad.

MdAPE

Error porcentual absoluto mediano; métrica principal de precisión del AVM.

PPE10

Porcentaje de predicciones con error menor o igual a 10%.

COS / CUS

Coeficientes de ocupación y utilización del suelo: huella y m² totales construibles.

Zonificación H/3/20

Habitacional, 3 niveles máximos, 20% de área libre mínima.

Valor residual

Lo que un desarrollador puede pagar por un predio dado el proyecto que la norma permite.

Isócrona

Polígono de los puntos alcanzables en un tiempo dado desde un origen.

Índice gravitacional

Accesibilidad agregada a polos de empleo ponderada por masa y decaimiento temporal.

Brier score

Métrica de calibración de pronósticos probabilísticos (menor es mejor).

Paper trading


Operar en papel: seguir las recomendaciones sin capital real para medir su calidad.

14.3 Anexo C — Preguntas que el sistema debe poder responder

La prueba de fuego del producto terminado es responder, con evidencia y en menos de un minuto cada una:

1. ¿Cuánto vale esta casa y qué tan seguro estás?
2. ¿Está cara o barata respecto a su zona y a su potencial constructivo?
3. ¿Mi colonia va a subir más que la inflación en 3 años? ¿Por qué señales?
4. ¿Qué colonias se “acercarán” a la ciudad cuando abra la próxima línea de transporte?
5. Tengo 30 MDP y 3 años: ¿cuáles son mis 5 mejores jugadas y qué riesgo agregado tomo?
6. ¿Qué tendría que ser cierto para que esta oportunidad fracase?

La pregunta 6 es la cultura de la empresa en una línea: todo análisis incluye su propia condición de falsificación.



CIMENTA — Inteligencia inmobiliaria cuantitativa
Plan maestro v1.0 · Junio 2026 · Documento confidencial